TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



ĐẶNG HỮU GIA HUÂN - 52300105
HỒ GIA KIỆN - 52300122

XÂY DỰNG HỆ THỐNG QUẢN LÝ TÀI LIỆU NGHIÊN CỨU KHOA HỌC TÍCH HỢP TRỢ LÝ AI SỬ DỤNG RAG

DỰ ÁN CÔNG NGHỆ THÔNG TIN

KHOA HỌC MÁY TÍNH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



ĐẶNG HỮU GIA HUÂN - 52300105
HỒ GIA KIỆN - 52300122

XÂY DỰNG HỆ THỐNG QUẢN LÝ TÀI LIỆU NGHIÊN CỨU KHOA HỌC TÍCH HỢP TRỢ LÝ AI SỬ DỤNG RAG

DỰ ÁN CÔNG NGHỆ THÔNG TIN

KHOA HỌC MÁY TÍNH

Người hướng dẫn

ThS. Dung Cẩm Quang

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Chúng em xin chân thành cảm ơn Thầy Dung Cẩm Quang đã tận tình hướng dẫn, hỗ trợ và đóng góp những ý kiến quý báu trong suốt quá trình thực hiện đề tài. Những kiến thức, kinh nghiệm và sự chỉ dẫn của Thầy đã giúp chúng em định hướng nghiên cứu, hoàn thiện phương pháp thực hiện cũng như từng bước khắc phục những khó khăn trong quá trình xây dựng hệ thống. Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày 25 tháng 10 năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

Huân

Đặng Hữu Gia Huân

Kiện

Hồ Gia Kiện

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH
TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi và được sự hướng dẫn khoa học của ThS. Dung Cẩm Quang. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Dự án còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào tôi xin hoàn toàn chịu trách nhiệm về nội dung Dự án của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 25 tháng 10 năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

Huân

Đặng Hữu Gia Huân

Kiện

Hồ Gia Kiện

XÂY DỰNG HỆ THỐNG QUẢN LÝ TÀI LIỆU NGHIÊN CỨU KHOA HỌC TÍCH HỢP TRỢ LÝ AI SỬ DỤNG RAG

TÓM TẮT

Trước sự gia tăng nhanh chóng của các công bố khoa học, việc quản lý và khai thác tri thức chuyên sâu đặt ra nhiều thách thức lớn. Đề tài "Xây dựng hệ thống quản lý tài liệu nghiên cứu khoa học tích hợp trợ lý AI sử dụng RAG" hướng đến phát triển một giải pháp toàn diện: kết hợp nền tảng quản lý tài liệu tập trung với trợ lý AI nhằm nâng cao hiệu quả tìm kiếm và tổng hợp thông tin có căn cứ.

Hệ thống được xây dựng dưới dạng ứng dụng web, cung cấp các tính năng: quản lý tài liệu theo bộ sưu tập (collections) và thẻ (tags); tự động trích xuất metadata qua định danh DOI; tích hợp trình đọc PDF và ghi chú tương tác. Trợ lý AI hỗ trợ hỏi đáp ngữ cảnh, tóm tắt nội dung và định vị chính xác trang trích dẫn nguồn trên tệp PDF, giúp người dùng dễ dàng kiểm chứng thông tin và giảm thiểu ảo giác của mô hình.

Trọng tâm nghiên cứu của đề tài là khảo sát và đánh giá thực nghiệm quy trình Retrieval-Augmented Generation (RAG) qua từng giai đoạn: trích xuất cấu trúc PDF, phân mảnh (chunking), biểu diễn vector (dense embedding), truy xuất kết hợp (hybrid search) và tổng hợp câu trả lời. Dựa trên kết quả đo lường định lượng trên tập dữ liệu bài báo khoa học chuẩn, các thành phần tối ưu được lựa chọn để hoàn thiện cấu hình RAG, bảo đảm cân bằng giữa chất lượng truy xuất, mức độ trung thực của câu trả lời và hiệu năng tính toán.

Đề tài mang lại một hệ thống thống nhất phục vụ nghiên cứu thực tế, đồng thời cung cấp cơ sở thực nghiệm rõ ràng cho việc lựa chọn và tối ưu hóa quy trình RAG chuyên sâu cho tài liệu học thuật.

MỤC LỤC

DANH MỤC HÌNH VẼ 7
DANH MỤC BẢNG BIỂU 8
DANH MỤC CÁC CHỮ VIẾT TẮT 10
CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI 1
1.1 Lý do chọn đề tài 1
1.2 Mục tiêu thực hiện đề tài 1
1.2.1. Mục tiêu tổng quát 1
1.2.2. Mục tiêu cụ thể 2
1.3. Đối tượng và phạm vi nghiên cứu 3
1.4. Phương pháp nghiên cứu 4
1.5. Ý nghĩa khoa học và thực tiễn của đề tài 5
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU 5
2.1 Các hệ thống quản lý tài liệu nghiên cứu 5
2.2 Retrieval-Augmented Generation (RAG) 6
2.3 Các hướng cải thiện pipeline RAG 6
2.3.1. Trích xuất văn bản từ tài liệu PDF 6
2.3.2. Phương pháp chia đoạn văn bản 6
2.3.3. Mô hình embedding và phương pháp truy xuất 7
2.4 Đánh giá hệ thống RAG 7
2.5 Nhận xét và định hướng nghiên cứu 7
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ THỰC NGHIỆM 8
3.1. Phương pháp nghiên cứu 8
3.2. Dữ liệu và môi trường thực nghiệm 9
3.2.1. Bộ dữ liệu thực nghiệm 9
3.2.2. Môi trường thực nghiệm 11
3.3. Thiết kế thực nghiệm theo câu hỏi nghiên cứu 11
3.3.1. Đánh giá phương pháp trích xuất văn bản PDF (RQ1) 12
3.3.2. Đánh giá chiến lược phân mảnh văn bản - Chunking (RQ2) 13
3.3.3. Đánh giá mô hình biểu diễn vector - Embedding (RQ3) 15
3.3.4. Đánh giá phương pháp truy xuất kết hợp - Hybrid Search (RQ4 - dự kiến) 16
3.3.5. Đánh giá mô hình sinh câu trả lời (LLM) (RQ5 - dự kiến) 17
3.3.6. Đánh giá cấu hình RAG kết hợp (RQ6 – dự kiến) 18
3.4. Tổng hợp các chỉ số đánh giá 19
3.5. Kiểm soát thực nghiệm và khả năng tái lập 20
3.6. Phạm vi thực hiện và giới hạn nghiên cứu hiện tại 21
3.6.1. Các nội dung đã thực hiện 21
3.6.2. Các nội dung dự kiến thực hiện 21
3.6.3. Giới hạn của nghiên cứu hiện tại 21

CHƯƠNG 4. PHÂN TÍCH, THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG 22
4.1 Phân tích yêu cầu hệ thống 22
4.1.1. Bài toán, người dùng và phạm vi 22
4.1.2. Yêu cầu chức năng 23
4.1.3. Yêu cầu phi chức năng 24
4.2 Phân tích quy trình nghiệp vụ và trường hợp sử dụng 25
4.2.1. Tác nhân 25
4.2.2. Các use case chính 26
4.3 Thiết kế kiến trúc hệ thống 29
4.3.1. Phong cách kiến trúc 29
4.3.2. Trách nhiệm các thành phần và luồng dữ liệu 30
4.4 Thiết kế cơ sở dữ liệu 33
4.4.1. Sơ đồ lớp (Class Diagram) 33
4.4.2. Các thực thể và ràng buộc dữ liệu 33
4.4.3. Liên kết giữa PostgreSQL và Qdrant 34
4.5. Thiết kế các quy trình xử lý chính 35
4.5.1. Quy trình nạp tài liệu và lập chỉ mục 35
4.5.2. Quy trình hỏi đáp sử dụng RAG 37
4.5.3. Xử lý ngoại lệ trong các quy trình 38
4.6. Thiết kế và triển khai giao diện người dùng 39
4.6.1. Bố cục giao diện ba cột 39
4.6.2. Các màn hình chính 41
4.7 Cài đặt các chức năng chính 42
4.7.1. Xác thực và quản lý phiên đăng nhập 42
4.7.2. Tải lên tài liệu và trích xuất metadata 43
4.7.3. Tổ chức, tìm kiếm và lọc tài liệu 43
4.7.4. Đọc PDF và quản lý chú thích 43
4.8. Cài đặt và tích hợp RAG 43
4.9 Hạn chế của hệ thống 44
CHƯƠNG 5. KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN 45
5.1. Phạm vi và đặc trưng dữ liệu thực nghiệm 45
5.1.1. Bộ dữ liệu QASPER 45
5.1.2. Ý nghĩa của các đặc trưng dữ liệu đối với thiết kế thực nghiệm 46
5.1.3. Các tập con dùng trong từng thí nghiệm 47
5.2. RQ1 – Đánh giá phương pháp trích xuất văn bản từ PDF 48
5.2.1. Thiết lập 48
5.2.2. Kết quả 49
5.2.3. Thảo luận 49
5.2.4. Quyết định lựa chọn 50
5.3. RQ2 – Đánh giá chiến lược chia đoạn văn bản (Chunking) 50
5.3.1. Khảo sát sơ bộ trên FiQA và QASPER 50

5.3.2. Động lực và thiết kế đánh giá mở rộng 52
5.3.3. Kết quả đánh giá mở rộng 54
5.3.4. Thảo luận và quyết định sử dụng hierarchical chunking 55
5.3.5. Kiểm chứng trên pipeline ứng dụng (production parity) 57
5.4. RQ3 – Đánh giá mô hình embedding và BM25 59
5.4.1. Thiết lập 59
5.4.2. Kết quả 60
5.4.3. Thảo luận 62
5.4.4. Quyết định lựa chọn 62
5.5. Tổng hợp lựa chọn cấu hình pipeline 63
5.6. Các hướng đánh giá tiếp theo: RQ4–RQ6 64
5.7. Giới hạn nghiên cứu 64
5.8 Kết luận chương 65
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 66
6.1 Kết luận 66
6.1.1 Về phần mềm 66
6.1.2 Về RAG 66
6.2 Hướng phát triển 67
6.2.1 Về phần mềm 67
6.2.2 Về RAG 67

DANH MỤC HÌNH VẼ

Hình 3.1. Sơ đồ Pipeline RAG

Hình 4.1. Sơ đồ usecase tổng hợp

Hình 4.2. Sơ đồ các thành phần kiến trúc hệ thống (Component Diagram)

Hình 4.3. Sơ đồ lớp của hệ thống quản lý tài liệu nghiên cứu khoa học

Hình 4.4. Sơ đồ tuần tự quy trình nạp tài liệu và lập chỉ mục (Sequence Diagram)

Hình 4.5. Sơ đồ tuần tự quy trình hỏi đáp sử dụng RAG (Sequence Diagram)

Hình 4.6. Giao diện tổng thể của hệ thống ở chế độ Thư viện.

Hình 4.7. Giao diện đọc tài liệu và truy cập các chức năng hỗ trợ.

Hình 4.8. Giao diện tải lên PDF và xem trước metadata.

Hình 4.9. Giao diện trợ lý AI và các nguồn trích dẫn.

Hình 5.1. Một số thông số về dataset QASPER

DANH MỤC BẢNG BIỂU

Bảng 3.1. Tổng hợp chỉ số đánh giá trong các thực nghiệm RQ1–RQ3 19

Bảng 4.1. Nhóm người dùng và nhu cầu chính 22

Bảng 4.2. Yêu cầu chức năng 23

Bảng 4.3. Yêu cầu phi chức năng 24

Bảng 4.4. Tác nhân của hệ thống 25

Bảng 4.5. Tổng quan use case 26

Bảng 4.6. Thành phần kiến trúc và công nghệ sử dụng 29

Bảng 4.7. Thực thể và quan hệ chính 32

Bảng 4.8. Vòng đời chỉ mục trong Qdrant 33

Bảng 5.1. Thống kê bộ dữ liệu QASPER 44

Bảng 5.2. Phân bố loại câu hỏi trong QASPER 44

Bảng 5.3. Tập dữ liệu sử dụng trong từng thí nghiệm 46

Bảng 5.4. Kết quả đánh giá các bộ trích xuất văn bản PDF (47 bài Dev) 47

Bảng 5.5. Kết quả khảo sát sơ bộ trên QASPER (k = 5) 50

Bảng 5.6. Kết quả khảo sát sơ bộ trên FiQA (k = 5) 50

Bảng 5.7. Kết quả tám chiến lược chia đoạn trên QASPER (47 bài, 127 câu hỏi, τ = 0,50) 52

Bảng 5.8. Phân tích độ nhạy theo ngưỡng liên quan τ (47 bài, 127 câu hỏi) 53

Bảng 5.9. So sánh section_overlap và hierarchical trên pipeline ứng dụng (47 bài, 127 câu hỏi, τ = 0,50) 55

Bảng 5.10. Đánh giá chất lượng truy xuất của các mô hình embedding và BM25 (xếp theo nDCG@10) 57

Bảng 5.11. Thông số kỹ thuật và chi phí tài nguyên tính toán của các mô hình embedding 58

Bảng 5.12. Tổng hợp kết quả thành phần và quyết định hiện tại 60

DANH MỤC CÁC CHỮ VIẾT TẮT

API	Application Programming Interface
BM25	Best Matching 25
CPU	Central Processing Unit
DOI	Digital Object Identifier
EDA	Exploratory Data Analysis
GPU	Graphics Processing Unit
IR	Information Retrieval
JWT	JSON Web Token
LLM	Large Language Model
MRR	Mean Reciprocal Rank
nDCG	normalized Discounted Cumulative Gain
RAG	Retrieval-Augmented Generation
RQ	Research Question
RRF	Reciprocal Rank Fusion
RSS	Resident Set Size
SPA	Single Page Application

CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI

1.1 Lý do chọn đề tài

Các nhà nghiên cứu thường phải quản lý nhiều bài báo khoa học và tra cứu thông tin nằm rải rác trong các tài liệu. Những công cụ như Zotero, Mendeley hay EndNote hỗ trợ tổ chức thư viện và thông tin tham khảo, nhưng việc tìm câu trả lời cho câu hỏi chuyên môn vẫn thường đòi hỏi người dùng đọc và đối chiếu PDF thủ công.

Các mô hình ngôn ngữ lớn có thể hỗ trợ hỏi đáp và tóm tắt, nhưng câu trả lời có thể không bám sát tài liệu nguồn hoặc khó kiểm chứng nếu thiếu dẫn chứng rõ ràng. Retrieval-Augmented Generation (RAG) (xem mục 2.2) giúp giải quyết vấn đề này. Tuy nhiên, hiệu quả RAG phụ thuộc vào nhiều lựa chọn kỹ thuật, bao gồm trích xuất văn bản PDF, phân mảnh tài liệu, mô hình embedding và chiến lược truy xuất.

Vì vậy, đề tài "Xây dựng hệ thống quản lý tài liệu nghiên cứu khoa học tích hợp trợ lý AI sử dụng RAG" hướng đến hai nội dung: phát triển ứng dụng web hỗ trợ quản lý và đọc tài liệu khoa học; đồng thời thực nghiệm đánh giá một số thành phần của pipeline RAG theo từng giai đoạn. Giai đoạn đầu tập trung vào trích xuất văn bản, phân mảnh và embedding. Các đánh giá mở rộng về truy xuất, mô hình ngôn ngữ và chất lượng câu trả lời sẽ được thực hiện khi có đủ điều kiện và kết quả ban đầu đã được rà soát. Đề tài không giả định trước phương pháp hay cấu hình nào là tối ưu.

1.2 Mục tiêu thực hiện đề tài

1.2.1. Mục tiêu tổng quát

Đề tài hướng đến hai mục tiêu có liên hệ với nhau: (1) phân tích, thiết kế và xây dựng một hệ thống web hỗ trợ quản lý tài liệu nghiên cứu khoa học, tích hợp trợ lý hỏi đáp dựa trên kiến trúc Retrieval-Augmented Generation (RAG); và (2) khảo sát thực nghiệm theo từng giai đoạn để hiểu ảnh hưởng của một số lựa chọn kỹ thuật trong pipeline RAG đối với khả năng truy xuất bằng chứng từ bài báo khoa học. Các kết quả ở giai đoạn đầu được dùng làm cơ sở cho những đánh giá tích hợp

tiếp theo nếu có đủ dữ liệu, thời gian và điều kiện thực nghiệm. Đề tài không mặc định trước một cấu hình là tốt nhất; mọi nhận định về phương pháp phù hợp cần dựa trên kết quả thực nghiệm có thể truy vết và kiểm tra lại.

1.2.2. Mục tiêu cụ thể

A. Phát triển hệ thống quản lý tài liệu

1. Xây dựng giao diện web để người dùng tổ chức thư viện tài liệu nghiên cứu, bộ sưu tập và thẻ nhãn; tìm kiếm và xem thông tin tài liệu.

2. Hỗ trợ nhập tệp PDF và tự động tra cứu một phần metadata học thuật từ DOI khi có dữ liệu phù hợp từ dịch vụ bên ngoài.

3. Tích hợp trình đọc PDF trong trình duyệt, cùng các chức năng chú thích hoặc ghi chú nằm trong phạm vi hiện thực hóa của hệ thống.

4. Tích hợp chức năng hỏi đáp trên nội dung tài liệu theo hướng RAG, nhằm đưa các đoạn văn bản được truy xuất vào ngữ cảnh cho mô hình sinh câu trả lời.

5. Kiểm thử các luồng chức năng chính của ứng dụng và ghi nhận các giới hạn còn tồn tại.

B. Đánh giá ban đầu một số thành phần của pipeline RAG (Giai đoạn 1)

1. Trích xuất văn bản PDF: khảo sát mức độ phù hợp của các phương pháp trích xuất đối với bài báo khoa học, dựa trên các tiêu chí có thể đo lường và tập bằng chứng được xác định cho thực nghiệm.

2. Phân mảnh văn bản (chunking): so sánh các chiến lược phân mảnh trong cùng điều kiện thực nghiệm, trên các tập dữ liệu khác nhau, xem xét cả đặc điểm của các đoạn tạo ra và hiệu quả truy xuất bằng chứng.

3. Mô hình dense embedding: so sánh một tập mô hình biểu diễn vector trên cùng hoặc các tập truy vấn tương thích, dựa trên chỉ số xếp hạng truy xuất và, khi được đo một cách nhất quán, các chỉ số tài nguyên tính toán.

4. Lưu giữ cấu hình thí nghiệm, dữ liệu đầu vào, mã đánh giá và tệp kết quả để các số liệu báo cáo có thể được đối chiếu với nguồn sinh ra chúng.

Giai đoạn này tập trung đánh giá từng thành phần ở mức ban đầu. Kết quả của một thí nghiệm riêng lẻ không tự động chứng minh rằng cấu hình đó là tốt nhất

trong toàn bộ pipeline, cũng không đồng nghĩa với việc chất lượng câu trả lời cuối cùng đã được xác nhận.

C. Định hướng đánh giá mở rộng (Giai đoạn 2)

Sau khi hoàn thiện và rà soát Giai đoạn 1, nghiên cứu có thể tiếp tục khảo sát chiến lược hybrid retrieval, mô hình ngôn ngữ lớn, chất lượng câu trả lời và tính ổn định trên các nhóm tài liệu khác nhau. Các đánh giá này cần được thiết kế và thực hiện riêng; chúng không được xem là đã hoàn thành chỉ vì đã có mã nguồn, cấu hình hoặc kế hoạch thí nghiệm. Việc kết hợp nhiều thành phần cũng chỉ nên được báo cáo sau khi các tổ hợp được chạy và đánh giá trực tiếp.

1.3. Đối tượng và phạm vi nghiên cứu

A. Đối tượng nghiên cứu

1. Quy trình Retrieval-Augmented Generation (RAG) dành cho tài liệu học thuật định dạng PDF, tập trung vào các thành phần chính của pipeline, bao gồm trích xuất văn bản, phân mảnh văn bản (chunking), biểu diễn văn bản bằng vector (embedding), truy xuất thông tin, tái xếp hạng kết quả (reranking) và tổng hợp câu trả lời dựa trên mô hình ngôn ngữ lớn (LLM). Các phương pháp thuộc từng thành phần được khảo sát thực nghiệm nhằm xác định những ứng viên phù hợp cho quá trình đánh giá kết hợp.

2. Các kỹ thuật và công nghệ hỗ trợ xây dựng hệ thống quản lý tài liệu nghiên cứu khoa học trên nền tảng web, bao gồm trích xuất siêu dữ liệu từ DOI, đọc và chú thích tệp PDF tương tác, quản lý tài liệu và định vị thông tin trích dẫn trên tài liệu gốc (citation grounding).

B. Phạm vi nghiên cứu

1. **Phạm vi nội dung và kỹ thuật**: Tập trung xây dựng hệ thống quản lý tài liệu nghiên cứu khoa học tích hợp trợ lý AI sử dụng RAG. Nghiên cứu thực nghiệm được tổ chức theo hai giai đoạn: (i) khảo sát sơ bộ các phương pháp thuộc từng thành phần của pipeline nhằm nhận diện những ứng viên có triển vọng dựa trên chất lượng truy xuất, chất lượng câu trả lời và chi phí tính toán tương ứng; (ii) lựa chọn và đánh giá một số tổ hợp đại diện của các thành phần trong pipeline nhằm phân

tích hiệu quả tổng thể và sự đánh đổi giữa chất lượng và tài nguyên sử dụng. Nghiên cứu không hướng đến việc kiểm thử toàn bộ các tổ hợp có thể có hoặc xác định một cấu hình tối ưu cho mọi loại tài liệu và điều kiện triển khai.

2. Phạm vi dữ liệu: Sử dụng tập dữ liệu bài báo khoa học bằng tiếng Anh có hỗ trợ đánh giá định lượng, trong đó QASPER được sử dụng làm nguồn dữ liệu chính cho các thí nghiệm phù hợp với đặc điểm của tập dữ liệu. Việc lựa chọn dữ liệu và phạm vi đánh giá được xác định theo từng giai đoạn thực nghiệm. Các kết quả được diễn giải trong giới hạn của tập dữ liệu và điều kiện thử nghiệm tương ứng.

3. Phạm vi ứng dụng: Xây dựng ứng dụng web phục vụ quản lý thư viện tài liệu khoa học cá nhân hoặc nhóm nghiên cứu quy mô nhỏ, hỗ trợ tổ chức, tìm kiếm, đọc và chú thích tài liệu PDF, đồng thời tích hợp trợ lý AI cho phép hỏi đáp dựa trên nội dung tài liệu. Hệ thống được sử dụng làm môi trường ứng dụng cho việc tích hợp và đánh giá cấu hình RAG được lựa chọn.

1.4. Phương pháp nghiên cứu

1. **Phương pháp nghiên cứu lý thuyết**: Tổng quan các công trình nghiên cứu liên quan đến kiến trúc RAG, mô hình ngôn ngữ lớn (LLM), các giải pháp xử lý văn bản PDF phức tạp và kỹ thuật truy xuất thông tin (IR).

2. **Phương pháp thực nghiệm**: Thiết kế các thí nghiệm sàng lọc sơ bộ cho những thành phần được lựa chọn trong pipeline RAG, bao gồm trích xuất văn bản, chunking, embedding, truy xuất thông tin, tái xếp hạng và sinh câu trả lời. Các phương pháp được so sánh trong những điều kiện phù hợp với từng giai đoạn, sử dụng các chỉ số đánh giá tương ứng như chất lượng truy xuất, độ chính xác của câu trả lời, mức độ trung thực với bằng chứng, thời gian xử lý và mức sử dụng tài nguyên. Dựa trên kết quả quan sát được và các tiêu chí lựa chọn xác định, một số ứng viên đại diện được đưa vào giai đoạn đánh giá kết hợp. Giai đoạn này tập trung so sánh hiệu quả đầu cuối của các cấu hình RAG được chọn, phân tích sự đánh đổi giữa chất lượng và chi phí tính toán, đồng thời xem xét độ tin cậy và các giới hạn

của kết quả. Các kết luận được giới hạn theo dữ liệu, thiết lập và quy mô thí nghiệm thực tế.

3. **Phương pháp phát triển phần mềm**: Áp dụng quy trình phân tích yêu cầu, thiết kế kiến trúc, phát triển và kiểm thử ứng dụng web với các thành phần frontend, backend, cơ sở dữ liệu quan hệ và cơ sở dữ liệu vector. Hệ thống được tích hợp các chức năng quản lý tài liệu, đọc PDF và trợ lý AI sử dụng RAG. Kiểm thử chức năng và đánh giá khả năng tích hợp được thực hiện nhằm xác minh mức độ đáp ứng yêu cầu của hệ thống trong phạm vi đề tài.

1.5. Ý nghĩa khoa học và thực tiễn của đề tài

1. Ý nghĩa khoa học: Cung cấp kết quả khảo sát thực nghiệm về một số phương pháp thuộc các thành phần của pipeline RAG trên dữ liệu bài báo khoa học, làm cơ sở lựa chọn ứng viên cho các thí nghiệm đánh giá kết hợp. Thông qua việc so sánh một số cấu hình RAG đại diện theo chất lượng truy xuất, chất lượng câu trả lời và chi phí tính toán, đề tài góp phần làm rõ ảnh hưởng của việc lựa chọn và kết hợp các thành phần đối với hiệu quả của hệ thống trong điều kiện thử nghiệm cụ thể. Kết quả đồng thời cung cấp cơ sở tham khảo cho các nghiên cứu ứng dụng RAG trong lĩnh vực tài liệu học thuật, trong giới hạn của dữ liệu và phương pháp đánh giá được sử dụng.

2. Ý nghĩa thực tiễn: Xây dựng hệ thống phần mềm hỗ trợ quản lý, tổ chức, tìm kiếm, đọc và chú thích tài liệu nghiên cứu khoa học, tích hợp trợ lý AI cho phép truy vấn thông tin từ nội dung tài liệu. Kết quả nghiên cứu thực nghiệm hỗ trợ việc lựa chọn cấu hình RAG phù hợp với yêu cầu về chất lượng và tài nguyên triển khai, góp phần nâng cao tính hữu ích của công cụ hỗ trợ tra cứu và khai thác tri thức từ các công bố khoa học.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

2.1 Các hệ thống quản lý tài liệu nghiên cứu

Các công cụ như Zotero, Mendeley và EndNote hỗ trợ lưu trữ, phân loại và quản lý tài liệu nghiên cứu. Tuy nhiên, việc tìm kiếm thông tin và tổng hợp nội

dung từ nhiều tài liệu vẫn có thể đòi hỏi người dùng đọc và đối chiếu thủ công. Đề tài kế thừa chức năng quản lý tài liệu tập trung, đồng thời tích hợp trợ lý AI để hỗ trợ khai thác nội dung tài liệu.

2.2 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) kết hợp cơ chế truy xuất thông tin từ nguồn dữ liệu bên ngoài với khả năng sinh văn bản của mô hình ngôn ngữ. Thay vì chỉ dựa vào kiến thức đã học trong quá trình huấn luyện, mô hình sử dụng các đoạn tài liệu liên quan làm ngữ cảnh để tạo câu trả lời.

Pipeline RAG cơ bản gồm hai giai đoạn:

- Lập chỉ mục: Trích xuất nội dung tài liệu, chia văn bản thành các đoạn và chuyển chúng thành vector embedding để lưu trữ.
- Truy vấn và sinh câu trả lời: Tìm kiếm các đoạn liên quan đến câu hỏi, sau đó đưa chúng vào mô hình ngôn ngữ để tạo câu trả lời.

Hiệu quả của RAG phụ thuộc vào sự phối hợp giữa các thành phần. Chất lượng trích xuất ảnh hưởng đến thông tin đầu vào; phương pháp chia đoạn quyết định cách tổ chức ngữ cảnh; embedding và cơ chế truy xuất ảnh hưởng đến khả năng tìm bằng chứng; còn mô hình ngôn ngữ quyết định cách diễn giải bằng chứng thành câu trả lời.

2.3 Các hướng cải thiện pipeline RAG

2.3.1. Trích xuất văn bản từ tài liệu PDF

Trích xuất văn bản là bước đầu tiên trong pipeline RAG. Các công cụ như PyMuPDF và pypdf hỗ trợ lấy văn bản từ PDF, trong khi GROBID tập trung vào việc nhận diện và cấu trúc hóa tài liệu khoa học. Phương pháp trích xuất cần bảo toàn nội dung hữu ích và trật tự văn bản, đồng thời hạn chế chi phí xử lý.

2.3.2. Phương pháp chia đoạn văn bản

Chunking chia tài liệu thành các đoạn nhỏ để lập chỉ mục và truy xuất. Đoạn quá ngắn có thể thiếu ngữ cảnh, trong khi đoạn quá dài có thể chứa thông tin không liên quan và làm tăng chi phí xử lý. Các phương pháp phổ biến gồm chia theo kích

thước cố định và chia theo cấu trúc văn bản như câu, đoạn hoặc mục. Việc lựa chọn cần cân bằng giữa khả năng giữ ngữ cảnh và độ chính xác khi truy xuất.

2.3.3. Mô hình embedding và phương pháp truy xuất

Embedding biểu diễn văn bản dưới dạng vector nhằm hỗ trợ tìm kiếm theo mức độ tương đồng ngữ nghĩa. Chất lượng truy xuất có thể khác nhau giữa các mô hình tùy thuộc vào đặc điểm văn bản và câu hỏi.

Bên cạnh truy xuất dense dựa trên vector, BM25 (Robertson & Zaragoza, 2009) là phương pháp truy xuất sparse dựa trên mức độ khớp từ vựng. Truy xuất hybrid kết hợp các phương pháp này để tận dụng cả thông tin ngữ nghĩa và sự trùng khớp từ khóa. Tuy nhiên, hiệu quả của từng phương pháp phụ thuộc vào bài toán và cần được đánh giá phù hợp.

2.4 Đánh giá hệ thống RAG

Đánh giá RAG cần xem xét riêng chất lượng truy xuất và chất lượng câu trả lời. Recall@k đo lường khả năng tìm được bằng chứng liên quan trong k kết quả đầu, trong khi nDCG@k đánh giá chất lượng xếp hạng các kết quả có liên quan. Đối với câu trả lời, cần xem xét độ chính xác của nội dung và mức độ câu trả lời được hỗ trợ bởi bằng chứng truy xuất. Thời gian xử lý và mức sử dụng bộ nhớ cũng là các tiêu chí quan trọng khi cân nhắc khả năng triển khai thực tế.

2.5 Nhận xét và định hướng nghiên cứu

Các nghiên cứu cho thấy RAG không phải một thành phần đơn lẻ mà là một pipeline gồm nhiều bước có thể ảnh hưởng lẫn nhau. Vì vậy, lựa chọn một mô hình embedding tốt chưa đủ để bảo đảm chất lượng câu trả lời cuối cùng; cần xem xét cả chất lượng dữ liệu đầu vào, cách chia đoạn, phương pháp truy xuất và khả năng sử dụng bằng chứng của mô hình ngôn ngữ.

Từ cơ sở đó, đề tài triển khai nghiên cứu theo từng giai đoạn. Giai đoạn đầu tập trung so sánh phương pháp trích xuất văn bản, chia đoạn và embedding. Giai đoạn tiếp theo hướng đến đánh giá phương pháp truy xuất kết hợp, mô hình ngôn ngữ và chất lượng câu trả lời, tùy theo tiến độ và kết quả giai đoạn đầu. Cách tiếp cận này nhằm lựa chọn cấu hình dựa trên thực nghiệm, đồng thời xem xét chất

lượng truy xuất, chất lượng câu trả lời và chi phí xử lý thay vì mặc định một phương pháp luôn tốt nhất.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ THỰC NGHIỆM

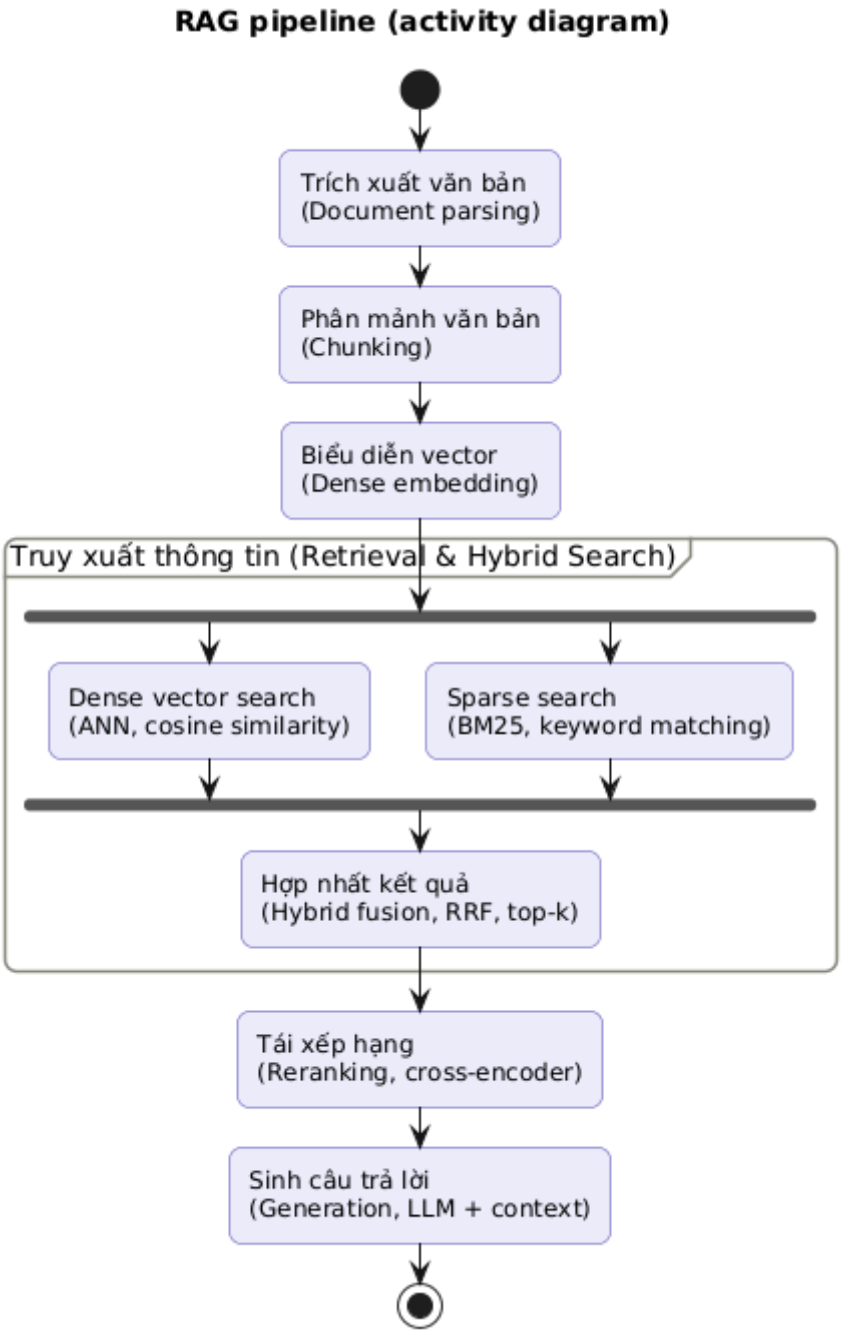
3.1. Phương pháp nghiên cứu

Đề tài kết hợp ba phương pháp: nghiên cứu tài liệu, phát triển phần mềm và thực nghiệm đối chứng có kiểm soát. Nghiên cứu tài liệu làm cơ sở lựa chọn kỹ thuật RAG; phát triển phần mềm phục vụ xây dựng hệ thống quản lý tài liệu nghiên cứu tích hợp trợ lý AI; thực nghiệm nhằm sàng lọc các phương pháp tiềm năng và đánh giá hiệu quả khi kết hợp chúng trong pipeline RAG.

Quy trình nghiên cứu gồm hai giai đoạn:

- **Giai đoạn 1 – Sàng lọc thành phần**: Khảo sát sơ bộ các phương pháp trích xuất văn bản PDF, phân mảnh văn bản, embedding, truy xuất thông tin và mô hình sinh câu trả lời. Kết quả được sử dụng để lựa chọn một số ứng viên đại diện cho giai đoạn tiếp theo. Nhóm đang ở bước này.
- **Giai đoạn 2 – Đánh giá tổ hợp**: Kết hợp các ứng viên được lựa chọn để đánh giá chất lượng truy xuất, chất lượng câu trả lời và chi phí tính toán của pipeline RAG đầu cuối

Sơ đồ pipeline RAG được biểu diễn trong hình dưới đây.



Hình 3.1. Sơ đồ Pipeline RAG

3.2. Dữ liệu và môi trường thực nghiệm

3.2.1. Bộ dữ liệu thực nghiệm

a. QASPER

QASPER (Question Answering on Scientific Papers) là bộ dữ liệu hỏi đáp trên bài báo khoa học tiếng Anh, cung cấp câu hỏi, nội dung bài báo và bằng chứng tham chiếu. Bộ dữ liệu chuẩn gồm 5.049 câu hỏi trên 1.585 bài báo, được sử dụng làm nguồn dữ liệu chính cho các thí nghiệm phù hợp với mục tiêu nghiên cứu. Do yêu cầu dữ liệu và điều kiện thực thi khác nhau giữa các thí nghiệm, nghiên cứu sử dụng các tập con tương ứng:

- RQ1 – Trích xuất PDF: 47 bài báo thuộc tập Dev và 4 bài báo thử nghiệm kỹ thuật (Đánh giá chất lượng trích xuất và bảo toàn cấu trúc)
- RQ2 – Chunking: 47 bài báo, 127 câu hỏi khả giải (Đánh giá ảnh hưởng của phân mảnh đến truy xuất bằng chứng)
- RQ3 – Embedding: 207 bài báo, 615 câu hỏi, 5.207 đoạn văn bản (So sánh chất lượng truy xuất và chi phí tính toán)

Các tập con được lựa chọn theo khả năng tiếp cận PDF, yêu cầu về bằng chứng và cấu hình đánh giá của từng thí nghiệm. Vì vậy, kết quả phản ánh hiệu năng trên các tập dữ liệu thực tế được sử dụng, không đại diện mặc nhiên cho toàn bộ QASPER hoặc mọi loại tài liệu khoa học. Đặc biệt, quy mô và cấu trúc dữ liệu cần được xét đến khi diễn giải mức độ chắc chắn của các so sánh thống kê.

b. FiQA

Nghiên cứu sử dụng bộ dữ liệu FiQA (Financial Question Answering) thuộc bộ chuẩn đánh giá BEIR (Thakur et al., 2021), được xây dựng phục vụ bài toán truy xuất thông tin và hỏi đáp trong lĩnh vực tài chính tiếng Anh. Bộ dữ liệu cung cấp các câu hỏi chuyên ngành cùng kho tài liệu bao gồm tin tức, báo cáo và các cuộc thảo luận tài chính, tạo cơ sở để đánh giá khả năng truy xuất thông tin trên các văn bản mang tính đặc thù cao.

Tùy theo mục tiêu và điều kiện của từng thí nghiệm, quy mô dữ liệu sử dụng có sự khác biệt:

- Phân mảnh văn bản (Chunking): Toàn bộ 57.600 đoạn văn bản thuộc tập tài liệu (corpus) (Mục tiêu: Đánh giá ảnh hưởng của các chiến lược phân mảnh

khác nhau — như phân mảnh kích thước cố định, đệ quy hay ngữ nghĩa — đến chất lượng truy xuất).

- Truy xuất thông tin (Embedding & Retrieval): Tập thử nghiệm gồm 6.650 câu hỏi (queries) đối chiếu với 57.600 đoạn văn bản (Mục tiêu: So sánh chất lượng truy xuất của các mô hình biểu diễn vector).

3.2.2. Môi trường thực nghiệm

Các thí nghiệm được thực hiện trong môi trường máy trạm cá nhân với cấu hình phần cứng và phần mềm được kiểm soát nhằm hỗ trợ khả năng tái lập kết quả:

- CPU: AMD Ryzen 5 5600, 6 nhân và 12 luồng.
- RAM: 16 GB DDR4.
- Hệ điều hành: Windows 11.
- Nền tảng xử lý: Python.
- Cơ sở dữ liệu vector: Qdrant, sử dụng ở chế độ embedded.
- Môi trường mô hình ngôn ngữ: Ollama chạy local.

Trong các thí nghiệm có sử dụng thư viện PyTorch, số luồng xử lý được giới hạn ở mức 4 theo cấu hình thực nghiệm. Hạt giống ngẫu nhiên được cố định ở mức 42 trong các quy trình có sử dụng lấy mẫu ngẫu nhiên, nhằm tăng khả năng tái lập kết quả.

3.3. Thiết kế thực nghiệm theo câu hỏi nghiên cứu

Nghiên cứu thực nghiệm được thiết kế nhằm đánh giá các thành phần chính trong pipeline Retrieval-Augmented Generation (RAG), bao gồm trích xuất văn bản PDF, phân đoạn văn bản (chunking), biểu diễn vector (embedding), chiến lược truy xuất và sinh câu trả lời. Trong phạm vi báo cáo hiện tại, ba câu hỏi nghiên cứu đầu tiên (RQ1–RQ3) tập trung vào việc đánh giá các thành phần riêng lẻ, tạo cơ sở cho việc lựa chọn cấu hình phù hợp. Các câu hỏi nghiên cứu tiếp theo (RQ4–RQ6) được xác định là hướng thực nghiệm dự kiến nhằm đánh giá chiến lược truy xuất, mô hình sinh và hiệu quả của pipeline RAG hoàn chỉnh.

Các thí nghiệm thành phần được thực hiện trên cùng dữ liệu đầu vào và theo các điều kiện kiểm soát phù hợp với từng câu hỏi nghiên cứu. Các chỉ số đánh giá

được lựa chọn dựa trên mục tiêu cụ thể của từng thí nghiệm, bao gồm chất lượng trích xuất, chất lượng truy xuất và chi phí tính toán. Kết quả được tổng hợp bằng bảng và biểu đồ để so sánh các phương pháp, nhận diện mức chênh lệch quan sát được và phân tích những đánh đổi giữa chất lượng với hiệu năng.

Nghiên cứu sử dụng phương pháp thống kê mô tả để phân tích kết quả, không thực hiện kiểm định giả thuyết thống kê hoặc sử dụng p-value và khoảng tin cậy để khẳng định sự khác biệt giữa các phương pháp. Do đó, các kết luận được giới hạn trong phạm vi dữ liệu và điều kiện thực nghiệm đã sử dụng.

3.3.1. Đánh giá phương pháp trích xuất văn bản PDF (RQ1)

Mục tiêu: Đánh giá khả năng trích xuất văn bản từ các bài báo khoa học của những thư viện xử lý PDF khác nhau, chú trọng độ trung thực của văn bản, khả năng nhận diện tiêu đề, bảo toàn thứ tự đọc và ảnh hưởng đến chất lượng truy xuất ở các bước tiếp theo.

Phương pháp so sánh: Năm phương pháp trích xuất văn bản cục bộ gồm *pymupdf_plain*, *pymupdf_layout*, *pypdf*, *pdfminer.six* và *pdfplumber* được đánh giá trên các tài liệu PDF thuộc bộ dữ liệu QASPER có sẵn trong môi trường thực nghiệm, kết hợp với một số tài liệu khoa học được lựa chọn để kiểm tra bổ sung. GROBID được xem xét trong thiết kế ban đầu nhưng không có kết quả đánh giá do dịch vụ không khả dụng trong lần thực nghiệm này.

Văn bản trích xuất và văn bản tham chiếu được chuẩn hóa trước khi đối chiếu nhằm hạn chế ảnh hưởng của khác biệt về khoảng trắng, dấu gạch nối và cách biểu diễn ký tự. Ngoài việc đánh giá trực tiếp chất lượng trích xuất, các phương pháp còn được xem xét thông qua chất lượng truy xuất trên một tập câu hỏi cố định, trong đó phương pháp phân đoạn và mô hình embedding được giữ nguyên để hạn chế ảnh hưởng của các thành phần khác.

Chỉ số đánh giá:

- **Character Match:** mức độ tương đồng giữa văn bản trích xuất và văn bản tham chiếu sau chuẩn hóa.

- **Heading F1:** khả năng nhận diện tiêu đề dựa trên độ chính xác và độ bao phủ của các tiêu đề được phát hiện.
- **Reading Order Concordance:** mức độ nhất quán của thứ tự đọc so với tài liệu tham chiếu.
- **Evidence Coverage:** tỷ lệ câu hỏi có bằng chứng tham chiếu được tìm thấy trong văn bản trích xuất theo quy tắc đánh giá đã xác định.
- **nDCG@10 và các chỉ số truy xuất liên quan:** đánh giá ảnh hưởng của văn bản trích xuất đến thứ hạng các đoạn liên quan.
- **Thời gian xử lý và Process Peak RSS:** phản ánh chi phí thời gian và bộ nhớ của tiến trình thực nghiệm.

Tiêu chí lựa chọn: Phương pháp được xem xét dựa trên chất lượng văn bản trích xuất, khả năng duy trì cấu trúc tài liệu, kết quả truy xuất và chi phí xử lý. Việc lựa chọn không dựa hoàn toàn vào một chỉ số riêng lẻ mà cân nhắc mức độ phù hợp với pipeline RAG và yêu cầu triển khai của hệ thống.

3.3.2. Đánh giá chiến lược phân mảnh văn bản - Chunking (RQ2)

Mục tiêu: Đánh giá tác động của các chiến lược phân đoạn văn bản khác nhau đến hiệu quả truy xuất ngữ cảnh và độ chính xác của bằng chứng được tìm thấy.

Phương pháp so sánh: Tám chiến lược phân đoạn được so sánh, bao gồm phân đoạn kích thước cố định, phân đoạn kích thước cố định có chồng lấp, phân đoạn theo ngữ nghĩa, phân đoạn theo cấu trúc mục, phân đoạn theo cấu trúc có giới hạn kích thước, phân đoạn theo cấu trúc có chồng lấp, phân đoạn phân cấp và phương pháp phân cấp không mở rộng đoạn cha khi truy xuất.

Các phương pháp sử dụng chung văn bản đầu vào từ phương pháp trích xuất được lựa chọn trong RQ1, mô hình embedding intfloat/e5-small-v2, tập câu hỏi, quy tắc xác định mức độ liên quan và ngân sách ngữ cảnh. Điểm tương đồng cosine được tính trên các vector đã chuẩn hóa để đảm bảo tính nhất quán trong việc xếp hạng kết quả.

Mức độ liên quan của một đoạn văn bản được xác định dựa trên tỷ lệ từ nội dung của bằng chứng tham chiếu được bao phủ bởi đoạn đó, sau khi loại bỏ các từ dừng theo quy tắc đã xác định. Một ngưỡng chính được sử dụng để đánh giá, kết hợp với một ngưỡng bổ sung nhằm xem xét độ nhạy của kết quả đối với quy tắc xác định mức độ liên quan.

Chỉ số đánh giá:

- **nDCG@10:** đánh giá chất lượng xếp hạng của các đoạn liên quan trong mười kết quả đầu tiên.
- **nDCG@4:** đánh giá chất lượng xếp hạng trong bốn kết quả đầu tiên.
- **Recall@20:** đo khả năng thu hồi các đoạn liên quan trong hai mươi kết quả đầu tiên.
- **MRR@10:** đánh giá thứ hạng của kết quả liên quan đầu tiên trong mười kết quả đầu tiên.
- **Truncation Rate:** tỷ lệ đoạn văn bản vượt quá giới hạn đầu vào của mô hình embedding và có nguy cơ bị cắt cụt.
- **Context Budget Coverage:** tỷ lệ câu hỏi có ít nhất một đoạn chứa bằng chứng liên quan trong phạm vi ngân sách ngữ cảnh quy định.

Các chỉ số này phản ánh những khía cạnh khác nhau của chất lượng truy xuất. Bên cạnh thứ hạng và khả năng thu hồi bằng chứng, tỷ lệ cắt cụt và mức độ bao phủ bằng chứng trong ngân sách ngữ cảnh giúp đánh giá tính phù hợp của các chiến lược phân đoạn đối với pipeline RAG.

Tiêu chí lựa chọn: Phương pháp được lựa chọn dựa trên chất lượng truy xuất, khả năng giữ lại bằng chứng, nguy cơ cắt cụt và mức độ tương thích với kiến trúc lưu trữ của hệ thống. Các kết quả được so sánh bằng giá trị đo được và mức chênh lệch giữa các phương pháp. Chi phí thời gian và bộ nhớ của từng chiến lược chỉ được đưa vào so sánh khi có dữ liệu đo lường tương ứng.

Ngân sách ngữ cảnh. Để so sánh công bằng các chiến lược chia đoạn có độ dài khác nhau, các khung đánh giá (RQ2 và so sánh trên pipeline ứng dụng) không

dùng số đoạn cố định mà nạp các đoạn có điểm cao nhất theo thứ tự cho đến khi tổng độ dài chạm ngân sách 1.600 token. Với section_overlap (độ dài trung bình 245,7 token mỗi đoạn), số đoạn nạp vào ngữ cảnh dao động từ 6 đến 14, trung bình 7,43 (trung vị 7,0). Với hierarchical, số mục cha nạp vào dao động từ 3 đến 14, trung bình 5,89 (trung vị 6,0).

3.3.3. Đánh giá mô hình biểu diễn vector - Embedding (RQ3)

Mục tiêu: So sánh chất lượng truy xuất của các mô hình embedding và đánh giá chi phí tính toán khi vận hành trên CPU, từ đó xác định mô hình phù hợp với yêu cầu về chất lượng và tài nguyên của hệ thống.

Phương pháp so sánh: Các mô hình embedding dense được đánh giá cùng phương pháp BM25 làm đối chứng dựa trên từ khóa. Nhóm mô hình được khảo sát bao gồm all-MiniLM-L6-v2, intfloat/e5-small-v2, BAAI/bge-small-en-v1.5, gte-small, các mô hình Snowflake Arctic, nomic-embed-text-v1.5, modernbert-embed-base và mxbai-embed-large-v1.

Các mô hình được đánh giá trên cùng tập tài liệu, tập câu hỏi và tập đoạn văn bản. Tiền tố truy vấn hoặc tài liệu được cấu hình theo từng mô hình. Các vector được chuẩn hóa và sử dụng cosine similarity để xếp hạng ứng viên trong phạm vi đánh giá, nhằm tập trung so sánh chất lượng biểu diễn vector mà không phụ thuộc vào sai số của thuật toán tìm kiếm gần đúng.

Các phép đo hiệu năng được thực hiện trên cùng môi trường phần cứng và cấu hình chạy đã xác định. Độ trễ truy vấn được đo sau giai đoạn làm nóng; thông lượng lập chỉ mục được đo theo kích thước lô thống nhất; bộ nhớ được ghi nhận thông qua mức sử dụng bộ nhớ thường trú cực đại của tiến trình benchmark.

Chỉ số đánh giá:

- **nDCG@10 và nDCG@4:** đánh giá chất lượng xếp hạng kết quả truy xuất.
- **Recall@20:** đo khả năng tìm được bằng chứng liên quan trong hai mươi kết quả đầu tiên.
- **MRR@10:** đánh giá thứ hạng của kết quả liên quan đầu tiên.

- **Query Latency P50 và P95:** phản ánh độ trễ truy vấn điển hình và ở phân vị cao.
- **Indexing Throughput:** số đoạn văn bản được mã hóa trong một đơn vị thời gian.
- **Process Peak RSS:** lượng bộ nhớ thường trú cực đại của tiến trình benchmark.

Tiêu chí lựa chọn: Các mô hình được so sánh dựa trên chất lượng truy xuất và chi phí tính toán. Mô hình có chất lượng truy xuất cao được xem xét cho cấu hình ưu tiên chất lượng; trong khi đó, mô hình có chất lượng phù hợp cùng độ trễ thấp, thông lượng cao và mức sử dụng bộ nhớ hợp lý có thể phù hợp hơn với điều kiện triển khai thực tế. BM25 được sử dụng làm phương pháp đối chiếu để làm rõ lợi ích và hạn chế của truy xuất dựa trên từ khóa so với truy xuất ngữ nghĩa.

Kết quả được trình bày bằng các chỉ số đo được và mức chênh lệch quan sát được giữa các mô hình. Nghiên cứu không sử dụng kiểm định giả thuyết để khẳng định mô hình nào vượt trội về mặt thống kê.

3.3.4. Đánh giá phương pháp truy xuất kết hợp - Hybrid Search (RQ4 - dự kiến)

Mục tiêu: Đánh giá khả năng cải thiện chất lượng truy xuất bằng cách kết hợp truy xuất từ khóa và truy xuất ngữ nghĩa, đồng thời xem xét lợi ích của bước tái xếp hạng kết quả nếu được triển khai.

Kế hoạch thực nghiệm: Dựa trên kết quả RQ1–RQ3, nghiên cứu dự kiến lựa chọn một số cấu hình truy xuất tiêu biểu, bao gồm truy xuất BM25, truy xuất vector và truy xuất kết hợp. Reciprocal Rank Fusion (RRF) có thể được sử dụng để hợp nhất thứ hạng từ các nguồn truy xuất. Bước tái xếp hạng bằng Cross-Encoder sẽ được xem xét nếu phù hợp với phạm vi triển khai và nguồn lực tính toán.

Các cấu hình dự kiến được đánh giá trên cùng tập câu hỏi, tập tài liệu và quy tắc xác định mức độ liên quan. Các thành phần không thuộc phạm vi so sánh sẽ được giữ cố định trong khả năng thực hiện.

Chỉ số dự kiến: nDCG@10, Recall@20, MRR@10 và độ trễ truy xuất. Nếu triển khai tái xếp hạng, thời gian xử lý tăng thêm cũng được ghi nhận.

Định hướng đánh giá: Kết quả dự kiến được dùng để xác định liệu việc kết hợp các phương pháp có mang lại cải thiện quan sát được so với phương pháp truy xuất riêng lẻ hay không. Việc lựa chọn cấu hình sẽ cân nhắc chất lượng truy xuất, chi phí xử lý và mức độ phức tạp khi tích hợp.

Truy xuất lai (BM25 kết hợp mô hình nhúng bằng Reciprocal Rank Fusion, hằng số làm mịn k = 60) đã được cài đặt và đang chạy trong ứng dụng; việc đánh giá thực nghiệm đối chứng so với truy xuất dense đơn lẻ trên cấu hình phân cấp hiện tại được dành cho giai đoạn tiếp theo.

3.3.5. Đánh giá mô hình sinh câu trả lời (LLM) (RQ5 - dự kiến)

Mục tiêu: Đánh giá khả năng sử dụng ngữ cảnh truy xuất để tạo câu trả lời chính xác và bám sát bằng chứng trong tài liệu nghiên cứu khoa học.

Kế hoạch thực nghiệm: Sau khi xác định được cấu hình truy xuất phù hợp, nghiên cứu dự kiến đánh giá mô hình ngôn ngữ chạy cục bộ trong điều kiện tài nguyên hiện có. Ollama với mô hình Llama 3.2 3B là một phương án dự kiến. Các mô hình hoặc cấu hình sinh bổ sung sẽ được xem xét tùy theo phạm vi triển khai.

Các mô hình được cung cấp cùng tập câu hỏi và ngữ cảnh truy xuất theo cấu trúc đầu vào thống nhất trong phạm vi có thể áp dụng chung. Việc đánh giá sẽ tập trung vào chất lượng câu trả lời thay vì chỉ dựa trên độ trôi chảy của văn bản.

Chỉ số dự kiến:

- **Answer Correctness:** mức độ chính xác của câu trả lời so với đáp án tham chiếu hoặc tiêu chí đánh giá được xác định.
- **Faithfulness:** mức độ các phát biểu trong câu trả lời được hỗ trợ bởi ngữ cảnh truy xuất.

- **Citation Accuracy:** mức độ chính xác của thông tin trích dẫn, bao gồm vị trí trang nguồn khi tính năng này được đánh giá.
- **Generation Latency và Tokens per Second:** phản ánh thời gian và tốc độ sinh câu trả lời.
- **Bộ nhớ sử dụng:** tài nguyên bộ nhớ cần thiết khi vận hành mô hình.

Định hướng đánh giá: Các kết quả dự kiến được sử dụng để so sánh chất lượng câu trả lời và chi phí vận hành giữa những phương án được thử nghiệm. Việc lựa chọn mô hình sẽ dựa trên các kết quả thực nghiệm thực tế, không mặc nhiên khái quát cho mọi lĩnh vực hoặc loại câu hỏi.

3.3.6. Đánh giá cấu hình RAG kết hợp (RQ6 – dự kiến)

Mục tiêu: Đánh giá hiệu quả của pipeline RAG hoàn chỉnh khi kết hợp các phương pháp được lựa chọn từ các giai đoạn thực nghiệm trước đó.

Kế hoạch thực nghiệm: Nghiên cứu dự kiến lựa chọn một số phương án tiêu biểu từ các giai đoạn trích xuất văn bản, phân đoạn, embedding, truy xuất và sinh câu trả lời để xây dựng các cấu hình RAG hoàn chỉnh. Thay vì thử nghiệm toàn bộ các tổ hợp có thể, số lượng cấu hình sẽ được giới hạn nhằm tập trung vào những phương án có cơ sở lựa chọn từ kết quả đánh giá thành phần.

Các cấu hình được dự kiến đánh giá trên cùng tập câu hỏi và điều kiện thực nghiệm. Khi xem xét ảnh hưởng của một thành phần, các thành phần còn lại sẽ được giữ cố định trong phạm vi có thể thực hiện để việc so sánh dễ diễn giải hơn.

Chỉ số dự kiến:

- **Chất lượng truy xuất:** nDCG@10, Recall@20 và MRR@10.
- **Answer Correctness:** mức độ chính xác của câu trả lời.
- **Faithfulness:** mức độ câu trả lời được hỗ trợ bởi ngữ cảnh truy xuất.
- **End-to-end Latency:** tổng thời gian xử lý từ truy vấn đến khi nhận được câu trả lời.

- **Bộ nhớ sử dụng:** lượng bộ nhớ cần thiết khi vận hành cấu hình được đánh giá.

Định hướng đánh giá: Kết quả dự kiến được tổng hợp thành bảng so sánh để thể hiện mối quan hệ giữa chất lượng truy xuất, chất lượng câu trả lời và chi phí tính toán. Cấu hình cuối cùng sẽ được lựa chọn dựa trên sự cân bằng giữa các tiêu chí này và khả năng tích hợp vào hệ thống quản lý tài liệu nghiên cứu khoa học. Các kết luận chỉ được đưa ra sau khi thí nghiệm tương ứng được thực hiện và kết quả được ghi nhận.

3.4. Tổng hợp các chỉ số đánh giá

Các chỉ số được lựa chọn tương ứng với mục tiêu của từng câu hỏi nghiên cứu. Bảng 3.1 tổng hợp các chỉ số chính được sử dụng trong giai đoạn đánh giá hiện tại và các nhóm chỉ số dự kiến cho những giai đoạn tiếp theo.

RQ	Nội dung khảo sát	Chỉ số đánh giá chính
RQ1	Trích xuất văn bản PDF	Char-Match, Heading F1, Reading Order, Evidence Coverage, Thời gian xử lý, Process Peak RSS, nDCG@10
RQ2	Chiến lược phân mảnh (Chunking)	nDCG@10, nDCG@4, Recall@20, MRR@10
RQ3	Mô hình embedding	nDCG@10, nDCG@4, Recall@20, MRR@10, Độ trễ mã hóa truy vấn P50, Thông lượng, Process Peak RSS

Bảng 3.1. Tổng hợp chỉ số đánh giá trong các thực nghiệm RQ1–RQ3

Ngưỡng liên quan τ: Một đoạn được coi là liên quan khi mức bao phủ từ vựng của đoạn đối với bằng chứng tham chiếu đạt ngưỡng τ. RQ2 dùng $\tau = 0{,}50$ làm ngưỡng chính, kèm phân tích độ nhạy ở $\tau = 0{,}30$ để kiểm tra thứ hạng các chiến lược có đổi khi tiêu chí nới lỏng hay không. RQ3 và phần đánh giá truy xuất hạ

nguồn của RQ1 dùng $\tau = 0,55$, lấy từ mô-đun đánh giá dùng chung; ngưỡng này được siết chặt hơn sau khi hiệu chỉnh nhằm loại các đoạn dài chỉ trùng ngẫu nhiên một số từ với bằng chứng. Vì vậy điểm của RQ2 và RQ3 không so sánh trực tiếp với nhau. Với chỉ số Evidence Coverage của RQ1, một bằng chứng được tính là bóc tách thành công nếu xuất hiện nguyên văn trong văn bản bóc tách hoặc có từ 75% từ vựng trở lên trùng khớp.

Các chỉ số nêu trên phục vụ đánh giá các thành phần đã được khảo sát trong giai đoạn đầu. Việc lựa chọn và áp dụng những chỉ số bổ sung sẽ được xem xét ở giai đoạn nghiên cứu tiếp theo, sau khi xác định rõ phạm vi và phương pháp thực nghiệm tương ứng.

3.5. Kiểm soát thực nghiệm và khả năng tái lập

Để đảm bảo tính nhất quán và khả năng kiểm tra lại kết quả, nghiên cứu áp dụng các nguyên tắc sau:

1. **Kiểm soát điều kiện so sánh:** Các phương pháp thuộc cùng một thí nghiệm sử dụng chung tập dữ liệu, tập câu hỏi và các điều kiện đánh giá không thuộc phạm vi khảo sát.
2. **Chuẩn hóa dữ liệu và tiêu chí liên quan:** Quy trình chuẩn hóa văn bản và quy tắc xác định đoạn liên quan được thống nhất trong từng thí nghiệm.
3. **Ghi nhận cấu hình:** Các tham số, phiên bản mô hình, cấu hình xử lý và kết quả được lưu trữ để hỗ trợ kiểm tra và tái lập.
4. **Báo cáo bằng thống kê mô tả:** Kết quả được trình bày bằng giá trị đo được, bảng và biểu đồ. Các mức chênh lệch được diễn giải như kết quả quan sát trong điều kiện thực nghiệm, không được xem là bằng chứng về sự khác biệt có ý nghĩa thống kê.
5. **Cân nhắc chất lượng và chi phí:** Khi các phương pháp có chất lượng quan sát tương đương, thời gian xử lý, bộ nhớ và độ phức tạp tích hợp được sử dụng làm căn cứ bổ sung cho việc lựa chọn.

6. **Phân biệt thiết kế với kết quả:** Chương thiết kế thực nghiệm mô tả mục tiêu, phương pháp, chỉ số và tiêu chí lựa chọn; các kết quả đo lường và thảo luận được trình bày ở chương kết quả.

3.6. Phạm vi thực hiện và giới hạn nghiên cứu hiện tại

3.6.1. Các nội dung đã thực hiện

Trong phạm vi báo cáo hiện tại, các thí nghiệm RQ1–RQ3 tập trung vào đánh giá phương pháp trích xuất văn bản PDF, chiến lược phân đoạn và mô hình embedding. Các kết quả thu được cung cấp cơ sở để nhận diện ưu điểm, hạn chế và sự đánh đổi giữa những phương pháp được thử nghiệm.

Tuy nhiên, kết quả của từng thí nghiệm thành phần không tự động chứng minh hiệu quả của toàn bộ hệ thống RAG, bởi chất lượng đầu ra cuối cùng còn phụ thuộc vào cách kết hợp các thành phần truy xuất và sinh câu trả lời.

3.6.2. Các nội dung dự kiến thực hiện

RQ4–RQ6 là các hướng thực nghiệm dự kiến, lần lượt tập trung vào chiến lược truy xuất, mô hình sinh câu trả lời và đánh giá pipeline RAG kết hợp. Các nội dung này chưa được xem là kết quả thực nghiệm hoàn chỉnh trong báo cáo hiện tại.

Việc triển khai sẽ phụ thuộc vào kết quả của các thí nghiệm thành phần, khả năng thực thi trên môi trường phần cứng hiện có và phạm vi thời gian của đề tài. Chỉ những thí nghiệm thực sự được triển khai mới được sử dụng làm căn cứ đưa ra kết luận trong báo cáo cuối cùng.

3.6.3. Giới hạn của nghiên cứu hiện tại

Nghiên cứu hiện tại có một số giới hạn cần lưu ý:

- **Phạm vi dữ liệu:** Các thí nghiệm chủ yếu sử dụng bài báo khoa học tiếng Anh thuộc bộ dữ liệu QASPER; khả năng áp dụng cho các nguồn tài liệu hoặc ngôn ngữ khác chưa được xác nhận đầy đủ.
- **Khác biệt giữa văn bản tham chiếu và PDF:** Việc đối chiếu văn bản trích xuất với nguồn tham chiếu có thể bị ảnh hưởng bởi cách biểu diễn công thức, trích dẫn, tiêu đề và bố cục.

- **Phạm vi đánh giá:** RQ1–RQ3 tập trung vào các thành phần riêng lẻ; chất lượng câu trả lời cuối cùng của toàn bộ hệ thống cần được đánh giá riêng.
- **Chi phí tài nguyên:** Các chỉ số thời gian và bộ nhớ chỉ phản ánh những thành phần đã được đo bằng quy trình tương ứng; không thể suy ra chi phí của toàn bộ pipeline từ một thành phần riêng lẻ.
- **Mức độ khái quát hóa:** Kết quả phản ánh tập dữ liệu, phần cứng và cấu hình đã sử dụng, không đủ để khẳng định một phương pháp luôn vượt trội trên mọi lĩnh vực hoặc loại tài liệu nghiên cứu.

Những giới hạn này được sử dụng làm cơ sở xác định phạm vi kết luận và định hướng cho các thí nghiệm tiếp theo.

CHƯƠNG 4. PHÂN TÍCH, THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG

4.1 Phân tích yêu cầu hệ thống

4.1.1. Bài toán, người dùng và phạm vi

Nhà nghiên cứu phải đọc, phân loại và ghi chú hàng chục đến hàng trăm bài báo PDF. Các công cụ như Zotero hay Mendeley giải quyết tốt việc lưu trữ và trích dẫn, nhưng người dùng vẫn phải tự đọc để tìm chi tiết kỹ thuật nằm rải rác trong bài. Dùng LLM trên đám mây để hỗ trợ đọc gặp ba rào cản: rò rỉ bản thảo chưa công bố, ảo giác (câu trả lời không có căn cứ) và chi phí. Các mô hình mã nguồn mở cỡ lớn lại đòi hỏi GPU đắt tiền. Đề tài xây dựng ứng dụng web quản lý tài liệu nghiên cứu tích hợp trợ lý AI dùng RAG, chạy hoàn toàn cục bộ trên máy trạm thông thường (CPU nhiều nhân, 16 GB RAM, không bắt buộc GPU).

Nhóm người dùng	Nhu cầu chính
Nhà nghiên cứu, giảng viên	Thư viện cá nhân có metadata chuẩn học thuật, thư mục phân cấp, tra cứu nhanh bằng AI mà không lộ dữ liệu.

Nhóm người dùng	Nhu cầu chính
Học viên cao học, sinh viên	Đọc tài liệu tiếng Anh, tóm tắt, nhảy thẳng đến trang chứa bằng chứng.

Bảng 4.1. Nhóm người dùng và nhu cầu chính

4.1.2. Yêu cầu chức năng

Mã	Yêu cầu	Mô tả	Trạng thái
FR-01	Xác thực và phiên	Đăng ký, đăng nhập; JWT gồm Access Token, tự làm mới bằng Refresh Token, vô hiệu hóa token khi đăng xuất (blacklist).	**Hoàn thành**
FR-02	Quản lý tệp PDF	Tải lên; kiểm tra đuôi tệp, dung lượng ≤ 50 MB và 4 byte đầu %PDF; xóa vào thùng rác hoặc xóa vĩnh viễn.	**Hoàn thành**
FR-03	Tự động trích xuất metadata	Trích tiêu đề, tác giả, arXiv ID, DOI từ PDF; tra cứu qua Crossref và OpenAlex; xem trước và chỉnh sửa trước khi lưu.	**Hoàn thành**
FR-04	22 trường thư mục	Xem và sửa tại chỗ (inline) 22 trường thư mục học thuật.	**Hoàn thành**
FR-05	Tổ chức và lọc	Cây thư mục lồng nhau, thẻ (tags), miền chuyên ngành (domains); tìm theo tiêu đề, tác giả, DOI; lọc Đọc gần đây, Công trình của tôi, Trùng lặp, Thùng rác.	**Hoàn thành**

Mã	Yêu cầu	Mô tả	Trạng thái
FR-06	Trình đọc PDF	Hiển thị bằng PDF.js, phóng to/thu nhỏ, chuyển trang, TextLayer để chọn văn bản bài báo hai cột.	**Hoàn thành**
FR-07	Highlight và ghi chú	Highlight 4 màu; sticky note kéo thả; đồng bộ về CSDL và thanh bên.	**Hoàn thành**
FR-08	Lập chỉ mục RAG	Tách chunk theo phân mảnh phân cấp (hierarchical): đoạn con khoảng 200 token, chồng lấp 40 token, mỗi đoạn con gắn với mục cha (parent_text); nhúng bằng intfloat/e5-small-v2, lưu Qdrant; trạng thái PENDING, INDEXING, INDEXED, FAILED.	**Hoàn thành**
FR-09	Hỏi đáp và tóm tắt	Truy xuất lai (Dense + BM25, hợp nhất bằng RRF với k = 60); sinh câu trả lời qua Ollama; giao diện hiển thị các huy hiệu trang [Page X] được tạo từ siêu dữ liệu của các mục đã truy xuất, nhấp vào để mở đúng trang PDF và đoạn trích; khi Ollama ngoại tuyến hoặc không trả lời, hệ thống trả về tối đa ba đoạn trích đầu tiên (mỗi đoạn tối đa 250 ký tự) kèm danh sách nguồn; tóm tắt một chạm.	**Hoàn thành**

Bảng 4.2. Yêu cầu chức năng

4.1.3. Yêu cầu phi chức năng

Mã	Nhóm	Nội dung
NFR-01	Khả năng sử dụng	Bố cục 3 cột kiểu Zotero; thanh bên tự thu hẹp khi đọc; phím tắt (Ctrl/Cmd+1..9, Ctrl/Cmd+F, Delete); huy hiệu trạng thái chỉ mục.
NFR-02	Hiệu năng trên phần cứng giới hạn	Chạy trên CPU Ryzen 5 5600, 16 GB RAM, không GPU; lập chỉ mục chạy luồng nền để không chặn HTTP; cây thư mục dựng O(N) từ một truy vấn SQL; mục tiêu truy xuất lai < 100 ms trên 30–80 chunk [thực tế đo được: P50 = 31,8 ms, P95 = 43,4 ms].
NFR-03	Truy vết nguồn	Câu trả lời chỉ dựa trên chunk truy xuất từ tài liệu; mỗi nguồn kèm page_number, section_title, snippet; bấm [Page X] để cuộn đến trang.
NFR-04	Bảo mật	Access Token 60 phút, Refresh Token 7 ngày, blacklist khi đăng xuất; kiểm tra byte %PDF; toàn bộ dữ liệu, vector và hội thoại AI lưu cục bộ.
NFR-05	Bảo trì	Tách SPA React và API Django REST; logic RAG cô lập trong RagService để đổi chiến lược chunking, mô hình nhúng hoặc LLM mà không ảnh hưởng module khác.

Bảng 4.3. Yêu cầu phi chức năng

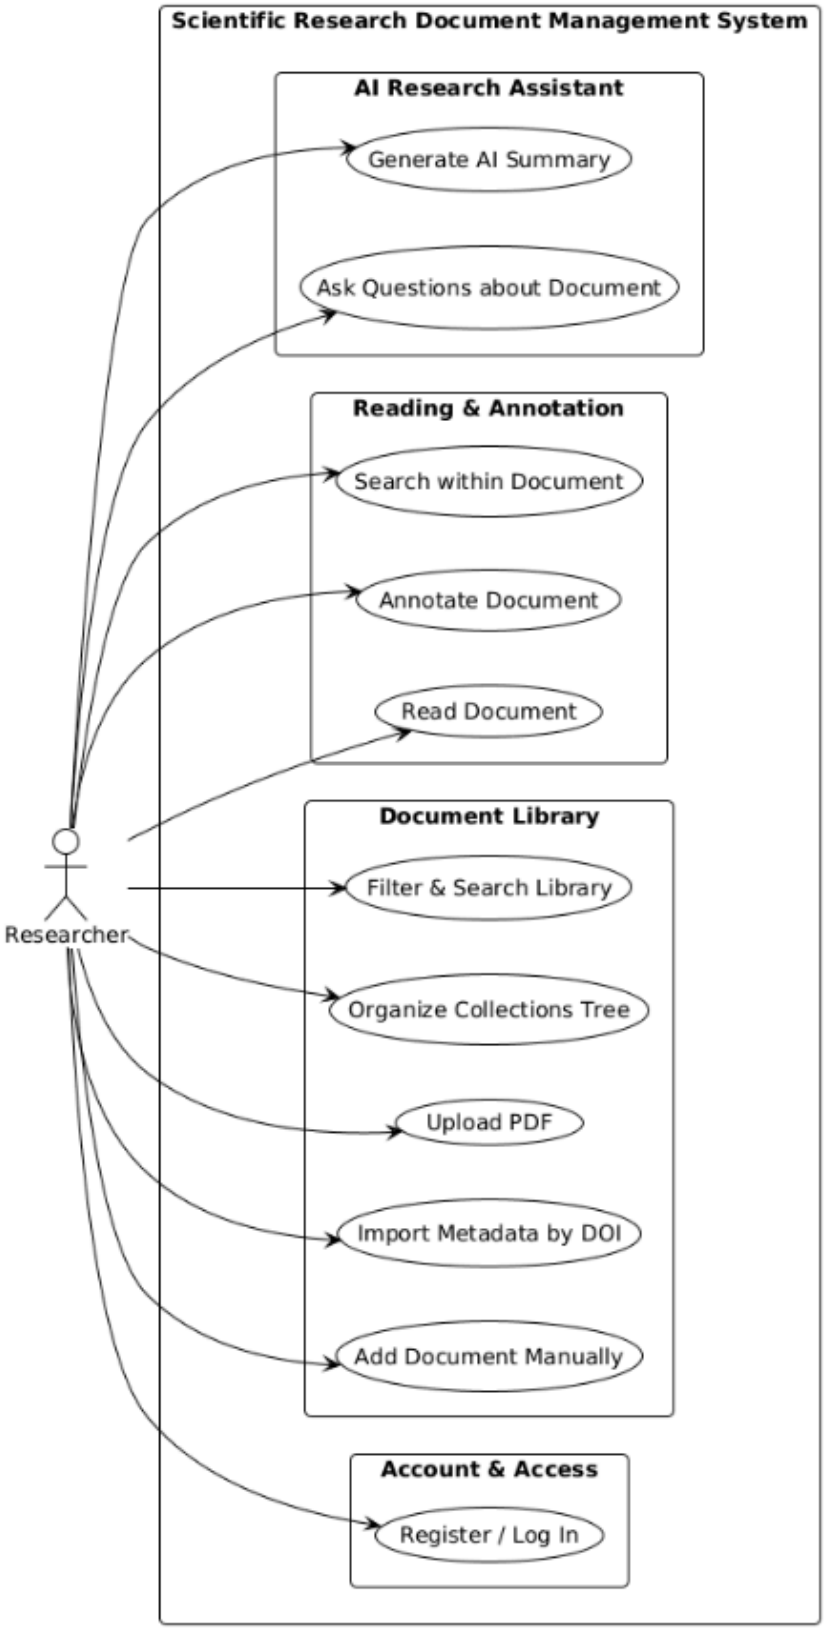
4.2 Phân tích quy trình nghiệp vụ và trường hợp sử dụng

4.2.1. Tác nhân

Tác nhân	Vai trò
Nhà nghiên cứu (người dùng thật)	Tác nhân chính: quản lý thư viện, đọc, chú thích, hỏi đáp AI.
Crossref / OpenAlex / arXiv API	Hệ thống ngoài, cung cấp metadata khi tra cứu DOI hoặc arXiv.
Ollama (LLM cục bộ)	Tiến trình nền trên cùng máy, sinh câu trả lời từ ngữ cảnh do RagService gửi tới.

Bảng 4.4. Tác nhân của hệ thống

4.2.2. Các use case chính



Hình 4.1. Sơ đồ usecase tổng hợp

Mã	Ca sử dụng	Điều kiện trước	Luồng chính	Luồng ngoại lệ
UC-01	Đăng nhập và truy cập thư viện	Có tài khoản	Đăng nhập, nhận cặp token; các request sau gửi Access Token; hết hạn thì tự làm mới.	Refresh Token nằm trong blacklist hoặc hết hạn: bị từ chối, yêu cầu đăng nhập lại.
UC-02	Tải lên PDF và trích metadata	Đã đăng nhập	(1) Chọn hoặc kéo thả PDF. (2) POST /metadata/extract-pdf/ trả bản xem trước. (3) Người dùng chỉnh sửa và xác nhận. (4) POST /documents/ lưu tệp, tạo bản ghi rag_status = PENDING, kích hoạt luồng nền, trả 201. (5) Tài liệu hiện trong thư viện với nhãn đang lập chỉ mục.	Thiếu %PDF hoặc sai định dạng: HTTP 400 và cảnh báo trên giao diện. Tệp > 50 MB: bị từ chối.
UC-03	Nhập tài liệu bằng DOI	Đã đăng nhập, có Internet	Nhập DOI, POST /metadata/lookup-doi/; Crossref trả kết quả, lỗi thì chuyển sang OpenAlex; hiển thị bản xem trước; xác nhận để tạo bản ghi (không cần tệp PDF).	Cả hai nguồn đều lỗi hoặc không tìm thấy: báo "DOI not found or invalid format".
UC-04	Đọc và chú thích	Tài liệu có tệp PDF	Mở trình đọc, bôi đen văn bản, chọn màu để tạo highlight hoặc	—

Mã	Ca sử dụng	Điều kiện trước	Luồng chính	Luồng ngoại lệ
			ghim sticky note; chú thích lưu về CSDL và hiện ở thanh bên.	
UC-05	Chia sẻ tài liệu cho người dùng khác	Có tài liệu sở hữu	Mô hình quyền VIEW, COMMENT, EDIT và lớp kiểm tra quyền đã có ở Backend. Chưa có giao diện chia sẻ, nên luồng người dùng cuối chưa hoàn chỉnh.	—
UC-06	Hỏi đáp AI có trích dẫn	Tài liệu INDEXED, Ollama đang chạy	(1) Nhập câu hỏi. (2) POST /documents/{id}/chat/. (3) RagService truy xuất Top-5 chunk, ghép prompt, gọi Ollama. (4) Trả câu trả lời kèm sources. (5) Bấm [Page X] để cuộn đến trang.	Ollama tắt hoặc quá 60 s: trả 3 trích đoạn điểm cao nhất, nhãn Grounded Hybrid RAG (Local).

Bảng 4.5. Tổng quan use case

4.3 Thiết kế kiến trúc hệ thống

4.3.1. Phong cách kiến trúc

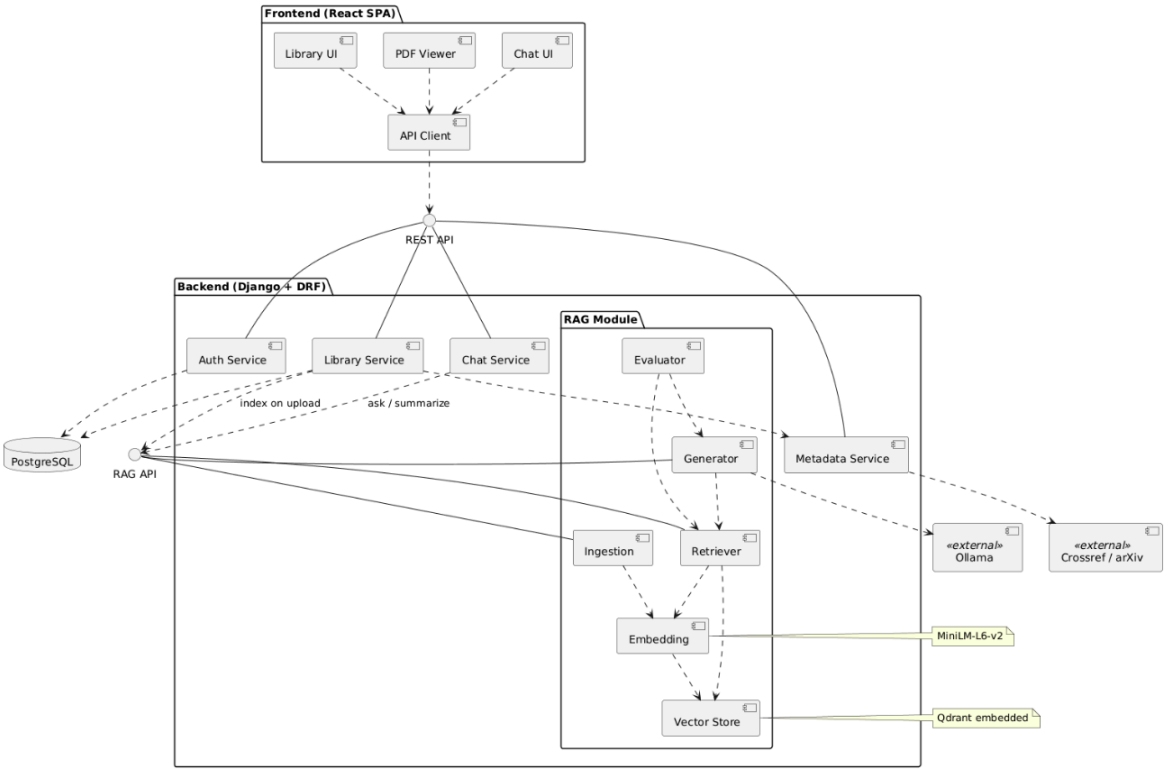
Hệ thống được thiết kế theo kiến trúc khối đơn mô-đun hóa (Modular Monolith), kết hợp giữa ứng dụng đơn trang (SPA) ở phía client và một tiến trình Django phân tầng ở phía server. Lựa chọn kiến trúc này dựa trên các lý do chính sau:

Môi trường triển khai local: Hệ thống hướng tới vận hành trên máy trạm cá nhân của nhà nghiên cứu, do đó kiến trúc vi dịch vụ (microservices) hoặc container hóa phức tạp sẽ tiêu tốn tài nguyên RAM không cần thiết và làm tăng độ trễ giao tiếp mạng nội bộ.

Tính nhất quán dữ liệu: Tiến trình Django đơn duy nhất giúp tận dụng giao dịch ACID của cơ sở dữ liệu PostgreSQL khi cập nhật thông tin tài liệu và đồng thời kích hoạt các tiến trình lập chỉ mục.

Ranh giới mô-đun được phân định rõ ràng: Mô-đun RAG và trích xuất PDF được đóng gói thành các lớp dịch vụ Python thuần túy trong thư mục apps/documents/services/, tách biệt với tầng định tuyến API. Luồng RAG chạy trực tiếp trong cùng tiến trình Django để tối ưu hiệu năng và đơn giản hóa việc quản lý trạng thái.

4.3.2. Trách nhiệm các thành phần và luồng dữ liệu



Hình 4.2. Sơ đồ các thành phần kiến trúc hệ thống (Component Diagram)

Thành phần	Công nghệ	Trách nhiệm	Giao tiếp
Frontend	React 19, TypeScript, Vite, CSS Modules, PDF.js	Hiển thị giao diện 3 cột, tương tác trình đọc PDF, vẽ chú thích, quản lý phím tắt và định vị trích dẫn nguồn.	Gửi các yêu cầu REST/JSON tới Backend API kèm theo JWT Authentication.
Backend API	Django 5, DRF, Python 3.12	Cung cấp endpoint REST, xác thực chuỗi JWT, kiểm tra ràng buộc dữ liệu, điều phối giao dịch và khởi chạy luồng nền lập chỉ mục.	Gọi trực tiếp các lớp dịch vụ nội bộ; giao tiếp HTTP với API bên ngoài và Ollama.
CSDL quan hệ	PostgreSQL 16	Lưu trữ thông tin tài khoản, cây thư mục, tài liệu cùng 22 trường metadata, ghi chú, chú thích và quyền truy cập.	Giao tiếp thông qua Django ORM.
Pipeline PDF và Lập chỉ mục	PyMuPDF, chunking_utils.py, daemon thread	Trích xuất văn bản theo cấu hình đề mục, chia nhỏ văn bản (chunking), đẩy vector và cập nhật trạng thái rag_status.	Chạy bất đồng bộ trong luồng nền của tiến trình Django.
Mô hình nhúng (Embedding)	intfloat/e5-small-v2 (384 chiều); FastEmbed ONNX	Mã hóa các đoạn văn bản ("passage: ") và câu hỏi truy vấn ("query: ") thành biểu diễn vector dense.	Gọi trực tiếp từ RagService.
CSDL Vector	Qdrant (Chế độ nhúng cục bộ tại media/qdrant_db/)	Lưu trữ tập trung các vector nhúng cùng payload dữ liệu của từng đoạn văn bản	Thư viện qdrant-client thực

Thành phần	Công nghệ	Trách nhiệm	Giao tiếp
		(chunk_id, page_number, section_title).	thi trực tiếp trong tiến trình Python.
Trợ lý AI (LLM)	Ollama (mô hình llama3.2:3b tại localhost:11434)	Tổng hợp và sinh câu trả lời từ ngữ cảnh các đoạn trích được truy xuất.	Yêu cầu HTTP POST từ RagService, hỗ trợ thời gian chờ tối đa 60 giây.

Bảng 4.6. Thành phần kiến trúc và công nghệ sử dụng

Các luồng xử lý dữ liệu cốt lõi trong hệ thống:

1. **Luồng nạp tài liệu và lập chỉ mục RAG:**

Khi người dùng tải lên tệp PDF từ giao diện SPA, Backend xác thực tệp và khởi tạo bản ghi trong PostgreSQL với trạng thái rag_status = PENDING. Ngay sau đó, một luồng nền (daemon thread) được kích hoạt để thực hiện trích xuất văn bản theo cấu trúc đề mục, chia nhỏ văn bản thành các đoạn (chunk) theo phân mảnh phân cấp (hierarchical): đoạn con khoảng 200 token, chồng lấp 40 token, mỗi đoạn con gắn với mục cha (parent_text), tạo biểu diễn vector bằng mô hình intfloat/e5-small-v2 và lưu trữ vào CSDL Qdrant. Sau khi hoàn tất, trạng thái tài liệu được cập nhật thành INDEXED.

2. **Luồng hỏi đáp và sinh câu trả lời có trích dẫn:**

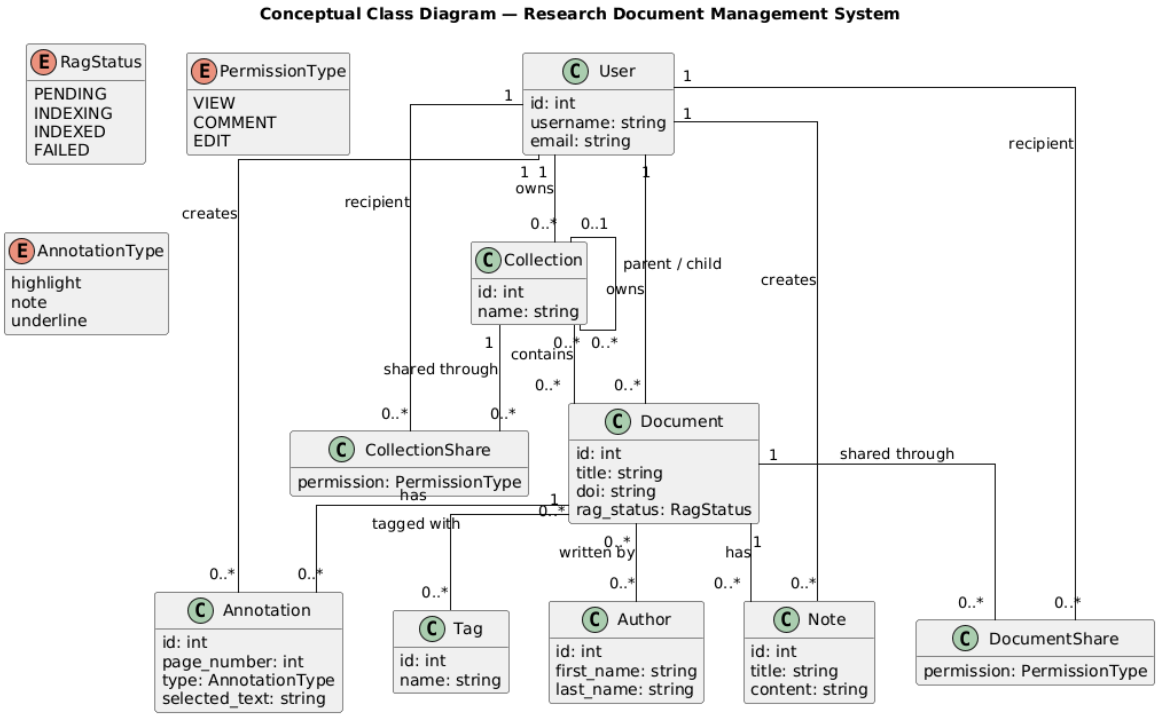
Khi người dùng gửi câu hỏi trong giao diện đọc tài liệu, yêu cầu được chuyển tới RagService. Dịch vụ thực hiện truy xuất kết hợp (Hybrid Search) kết hợp giữa tìm kiếm ngữ nghĩa vector trên Qdrant và tìm kiếm từ khóa BM25, sau đó hợp nhất kết quả bằng thuật toán Reciprocal Rank Fusion (RRF) để chọn các mục cha đưa vào ngữ cảnh, trong ngân sách tối đa 1.600 token và không quá 5 mục cha. Ngữ cảnh này được đóng gói vào prompt gửi tới mô hình Ollama (llama3.2:3b) cục bộ. Câu trả lời trả về cho Frontend đi kèm danh sách trích dẫn (sources) chứa thông

tin số trang và tiêu đề mục, cho phép hiển thị các huy hiệu [Page X] để cuộn trực tiếp tới trang tài liệu tương ứng.

4.4 Thiết kế cơ sở dữ liệu

4.4.1. Sơ đồ lớp (Class Diagram)

Sơ đồ lớp dưới đây mô tả các thực thể chính của hệ thống quản lý tài liệu nghiên cứu khoa học và mối quan hệ giữa chúng. Sơ đồ tập trung vào cấu trúc dữ liệu ở mức khái niệm, bao gồm người dùng, tài liệu, bộ sưu tập, tác giả, thẻ, ghi chú, chú thích và các thực thể phục vụ chia sẻ tài liệu. Các thuộc tính chi tiết và cấu trúc bảng vật lý được trình bày trong phần mô tả các thực thể và ràng buộc dữ liệu.



Hình 4.3. Sơ đồ lớp của hệ thống quản lý tài liệu nghiên cứu khoa học

4.4.2. Các thực thể và ràng buộc dữ liệu

Nhóm	Bảng	Ghi chú thiết kế
Lõi	users, documents, collections, authors, tags, domains, document_groups, annotations, notes	documents là trung tâm; có chỉ mục (index) trên doi để tra cứu và phát hiện trùng.
Bảng trung gian (M:N)	document_authors, document_tags, document_domains, document_collections	document_authors có author_order để giữ thứ tự tác giả (tác giả đầu, tác giả liên hệ).
Mở rộng cho cộng tác	document_shares, collection_shares, related_documents	Đã có model và migration; chỉ phần phân quyền được kiểm thử ở Backend.

Bảng 4.7. Thực thể và quan hệ chính

Điểm thiết kế cần lưu ý:

1. **Cây thư mục:** collections.parent_id tự tham chiếu; parent_id = NULL là thư mục gốc.
2. **Trạng thái chỉ mục:** documents.rag_status nhận PENDING, INDEXING, INDEXED, FAILED.
3. **Chú thích:** annotations.rects là mảng JSON lưu tọa độ pixel của vùng chọn (dự kiến chuẩn hóa theo phần trăm trang trong tương lai), selected_text lưu văn bản được chọn để hiện trên thanh bên mà không cần mở PDF.
4. **Sở hữu và chia sẻ:** quyền sở hữu qua khóa ngoại chủ sở hữu; chia sẻ qua document_shares và collection_shares với 3 mức VIEW, COMMENT, EDIT, kiểm tra bởi IsOwnerOrCollaborator.

4.4.3. Liên kết giữa PostgreSQL và Qdrant

Hai kho được tách rời và nối với nhau bằng định danh tất định, không cần thêm cột khóa ngoại. Mỗi điểm trong Qdrant gồm vector 384 chiều và payload document_id, chunk_id, page_number, section_title, text.

Sự kiện	Xử lý
Tải lên	Tạo bản ghi PENDING; luồng nền ghi vector vào Qdrant và đặt INDEXED (lỗi thì FAILED).
Re-index	Ghi đè (upsert) vector của tài liệu bằng vector tính lại.
Xóa vĩnh viễn	Xóa tệp trong media/documents/, xóa các điểm theo document_id trong Qdrant, xóa bản ghi PostgreSQL (CASCADE sang chú thích, ghi chú, liên kết tác giả).

Bảng 4.8. Vòng đời chỉ mục trong Qdrant

4.5. Thiết kế các quy trình xử lý chính

Mục này trình bày trình tự xử lý của hai chức năng cốt lõi trong hệ thống, bao gồm quy trình nạp tài liệu và lập chỉ mục phục vụ truy xuất tăng cường bằng sinh (Retrieval-Augmented Generation – RAG), và quy trình hỏi đáp dựa trên nội dung tài liệu. Các quy trình được mô tả nhằm làm rõ sự phối hợp giữa giao diện người dùng, backend, cơ sở dữ liệu quan hệ, cơ sở dữ liệu vector và mô hình ngôn ngữ.

4.5.1. Quy trình nạp tài liệu và lập chỉ mục

Quy trình nạp tài liệu bắt đầu khi người dùng tải lên một tệp PDF thông qua giao diện web. Backend kiểm tra tính hợp lệ của tệp trước khi lưu trữ và tạo bản ghi tài liệu trong PostgreSQL. Sau đó, hệ thống thực hiện các bước xử lý nội dung để chuẩn bị dữ liệu cho chức năng hỏi đáp.

Quy trình gồm các bước chính:

1. Tiếp nhận và kiểm tra tệp: Frontend gửi tệp PDF đến backend. Backend kiểm tra định dạng và giới hạn kích thước theo quy định của hệ thống.

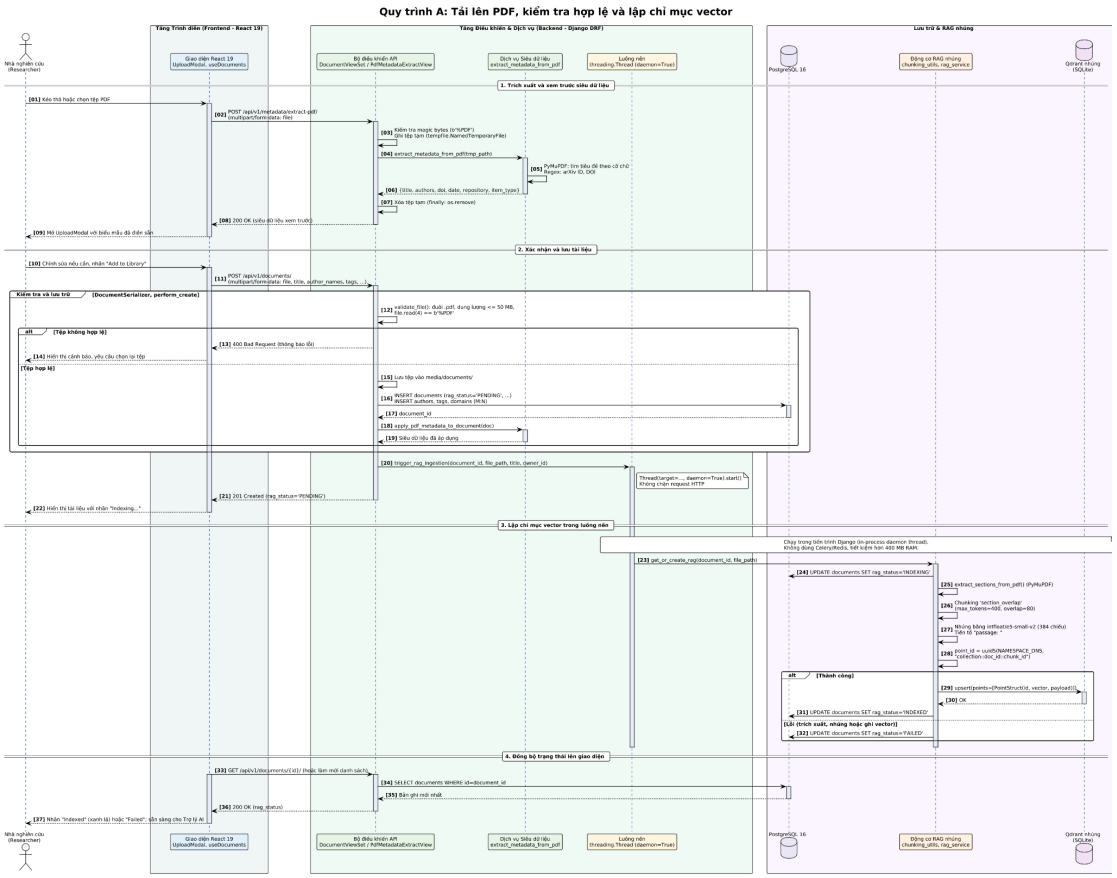
2. Lưu trữ tài liệu: Nếu tệp hợp lệ, hệ thống lưu tệp và tạo bản ghi tương ứng trong PostgreSQL. Trạng thái lập chỉ mục ban đầu được thiết lập để thể hiện tài liệu đang chờ xử lý.

3. Trích xuất văn bản: Pipeline xử lý PDF đọc nội dung văn bản từ tệp, đồng thời thu thập thông tin nguồn cần thiết cho việc truy xuất, chẳng hạn như số trang và tiêu đề mục nếu có.

4. Chia đoạn văn bản: Nội dung trích xuất được chia thành các đoạn nhỏ theo phương pháp chunking đang được sử dụng. Mỗi đoạn cần duy trì thông tin liên kết với tài liệu gốc để phục vụ việc xác định nguồn sau này.

5. Tạo vector và lưu trữ: Các đoạn văn bản được chuyển thành vector bằng mô hình nhúng đã cấu hình. Vector cùng payload chứa thông tin liên quan được ghi vào Qdrant.

6. Cập nhật trạng thái: Sau khi xử lý hoàn tất, hệ thống cập nhật trạng thái lập chỉ mục của tài liệu. Nếu xảy ra lỗi, trạng thái lỗi được ghi nhận để hỗ trợ kiểm tra và xử lý lại.



Hình 4.4. Sơ đồ tuần tự quy trình nạp tài liệu và lập chỉ mục (Sequence Diagram)

4.5.2. Quy trình hỏi đáp sử dụng RAG

Quy trình hỏi đáp sử dụng RAG (xem mục 2.2) cho phép người dùng đặt câu hỏi liên quan đến nội dung tài liệu đã được lập chỉ mục.

Quy trình gồm các bước chính:

1. Tiếp nhận câu hỏi: Người dùng gửi câu hỏi từ giao diện đọc tài liệu. Backend tiếp nhận yêu cầu và kiểm tra quyền truy cập đối với tài liệu tương ứng.

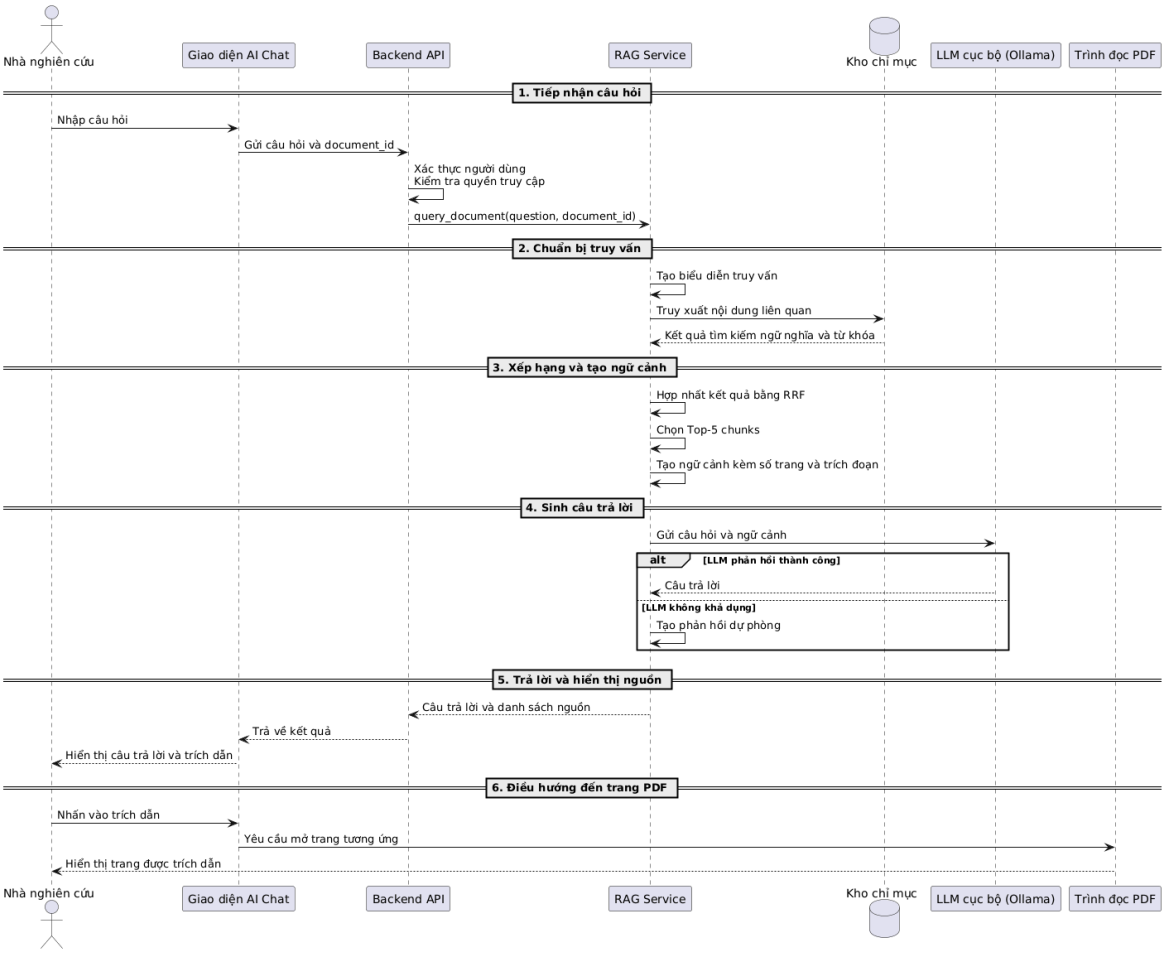
2. Chuẩn bị truy vấn: Dịch vụ RAG chuyển câu hỏi thành dạng biểu diễn phù hợp với phương pháp truy xuất đang sử dụng.

3. Truy xuất nội dung liên quan: Hệ thống tìm kiếm các đoạn văn bản phù hợp trong dữ liệu đã lập chỉ mục. Tùy cấu hình, quá trình này có thể sử dụng tìm kiếm vector, tìm kiếm từ khóa hoặc kết hợp nhiều phương pháp.

4. Tổng hợp ngữ cảnh: Các kết quả truy xuất được lựa chọn và tổng hợp thành ngữ cảnh đầu vào cho mô hình ngôn ngữ.

5. Sinh câu trả lời: Backend gửi câu hỏi cùng ngữ cảnh đến mô hình ngôn ngữ đã cấu hình. Mô hình tạo câu trả lời dựa trên thông tin được cung cấp.

6. Trả kết quả và nguồn tham chiếu: Backend trả về câu trả lời cùng thông tin nguồn của các đoạn được sử dụng. Frontend hiển thị kết quả và hỗ trợ người dùng đối chiếu với nội dung tài liệu gốc.



Hình 4.5. Sơ đồ tuần tự quy trình hỏi đáp sử dụng RAG (Sequence Diagram)

Truy xuất lai thực hiện bốn bước: (1) tính độ tương đồng cosine giữa vector truy vấn và vector các đoạn con (mô hình intfloat/e5-small-v2); (2) tính điểm BM25 trên cùng tập đoạn; (3) hợp nhất hai bảng xếp hạng bằng Reciprocal Rank Fusion, trong đó điểm của mỗi đoạn là tổng 1/(60 + hạng_dense) và 1/(60 + hạng_BM25); (4) mở rộng các đoạn con trúng khớp sang mục cha duy nhất (loại trùng); mục cha dài hơn 800 token được cắt cửa sổ khoảng 200 từ mỗi bên quanh đoạn con trúng; quá trình dừng khi tổng độ dài vượt ngân sách 1.600 token, và ứng dụng giữ tối đa 5 mục cha để đưa vào prompt cho mô hình ngôn ngữ.

4.5.3. Xử lý ngoại lệ trong các quy trình

Ngoài luồng xử lý thông thường, hệ thống cần xem xét các tình huống lỗi có thể xảy ra trong quá trình vận hành.

- Tệp PDF không hợp lệ hoặc vượt giới hạn cho phép: Từ chối yêu cầu và trả thông báo lỗi cho giao diện.

- Lỗi khi trích xuất hoặc lập chỉ mục: Ghi nhận trạng thái lỗi của tài liệu để hỗ trợ kiểm tra và xử lý lại.

- Tài liệu chưa được lập chỉ mục hoàn tất: Thông báo trạng thái phù hợp và không thực hiện hỏi đáp dựa trên dữ liệu chưa sẵn sàng.

- Không tìm thấy đoạn văn bản phù hợp: Trả về thông báo rằng hệ thống chưa tìm được đủ thông tin liên quan, thay vì khẳng định một câu trả lời không có căn cứ.

- Mô hình ngôn ngữ không phản hồi hoặc xảy ra lỗi: Trả thông báo lỗi hoặc sử dụng cơ chế dự phòng nếu cơ chế đó đã được triển khai và kiểm thử.

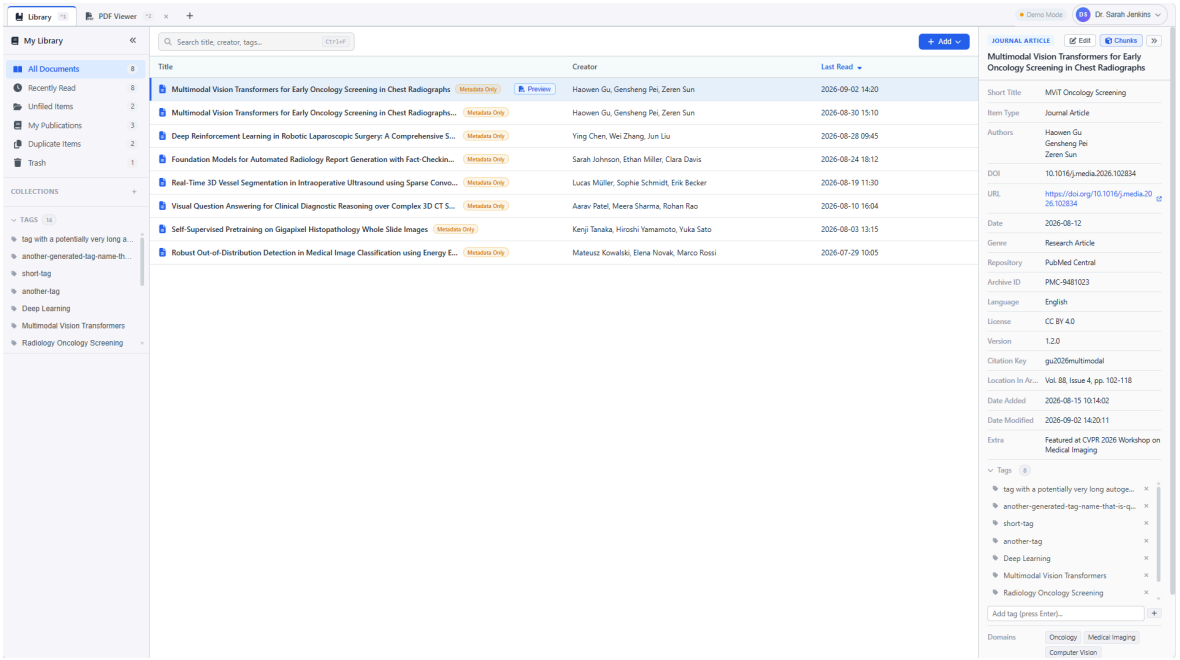
- Không đủ quyền truy cập tài liệu: Từ chối yêu cầu theo quy tắc phân quyền của hệ thống.

Tóm lại, hai quy trình trên thể hiện cách hệ thống chuyển tài liệu PDF thành dữ liệu có thể truy xuất và sử dụng dữ liệu đó để hỗ trợ hỏi đáp. Việc tách riêng quy trình lập chỉ mục và quy trình hỏi đáp giúp xác định rõ trách nhiệm của từng thành phần, đồng thời tạo cơ sở để đánh giá hiệu quả của các phương pháp RAG trong phần thực nghiệm.

4.6. Thiết kế và triển khai giao diện người dùng

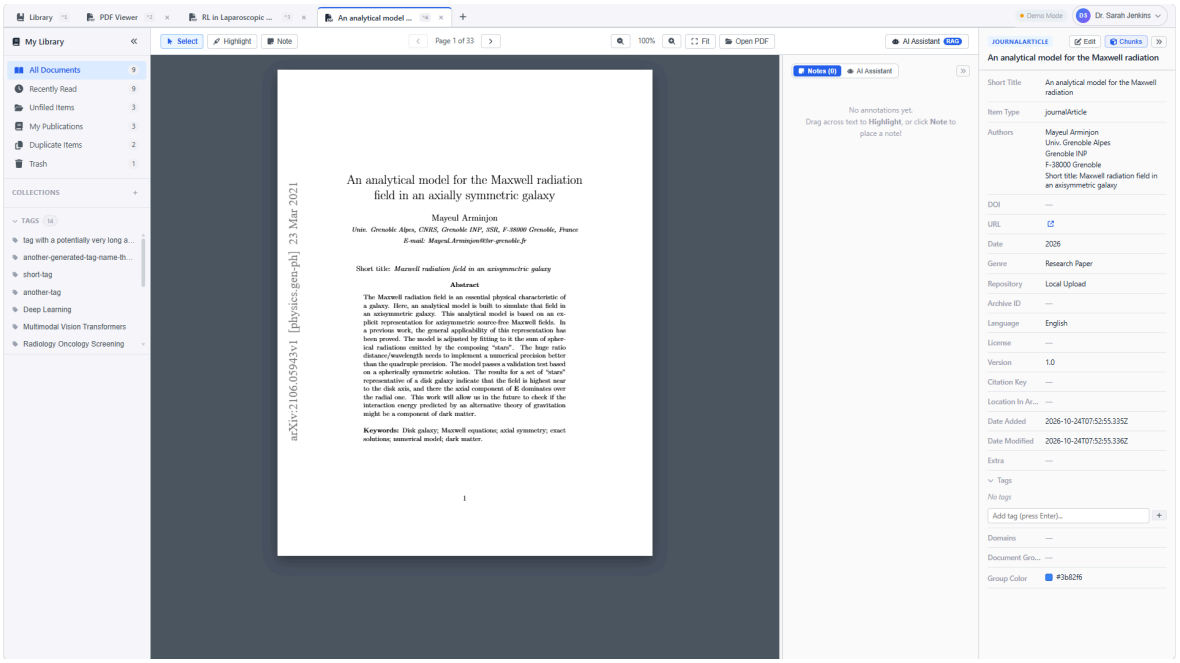
4.6.1. Bố cục giao diện ba cột

Giao diện hệ thống được tổ chức theo bố cục ba cột nhằm hỗ trợ đồng thời việc quản lý tài liệu, đọc nội dung nghiên cứu và khai thác các chức năng hỗ trợ. Tùy theo chế độ sử dụng, nội dung của từng cột được điều chỉnh để phù hợp với tác vụ hiện tại.



Hình 4.6. Giao diện tổng thể của hệ thống ở chế độ Thư viện.

Trong chế độ Thư viện, cột bên trái cung cấp các danh mục và công cụ phân loại tài liệu, cột giữa hiển thị danh sách tài liệu cùng các chức năng tìm kiếm và thêm tài liệu, trong khi cột bên phải hiển thị thông tin của tài liệu được chọn.



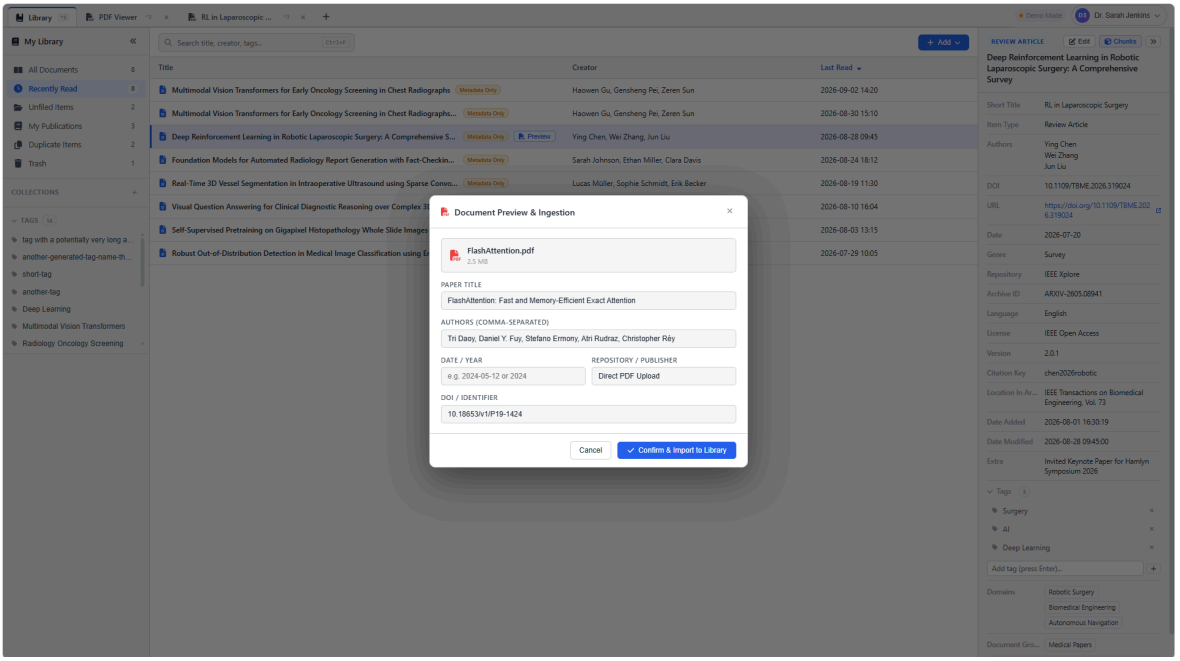
Hình 4.7. Giao diện đọc tài liệu và truy cập các chức năng hỗ trợ.

Ở chế độ Đọc, khu vực trung tâm hiển thị nội dung PDF. Người dùng có thể truy cập các chức năng chú thích và trợ lý AI từ khu vực chức năng bên cạnh, hỗ trợ việc đọc và tra cứu thông tin trong cùng một môi trường làm việc.

Bố cục ba cột giúp phân tách các nhóm thao tác chính gồm quản lý tài liệu, xem nội dung và khai thác thông tin bổ sung.

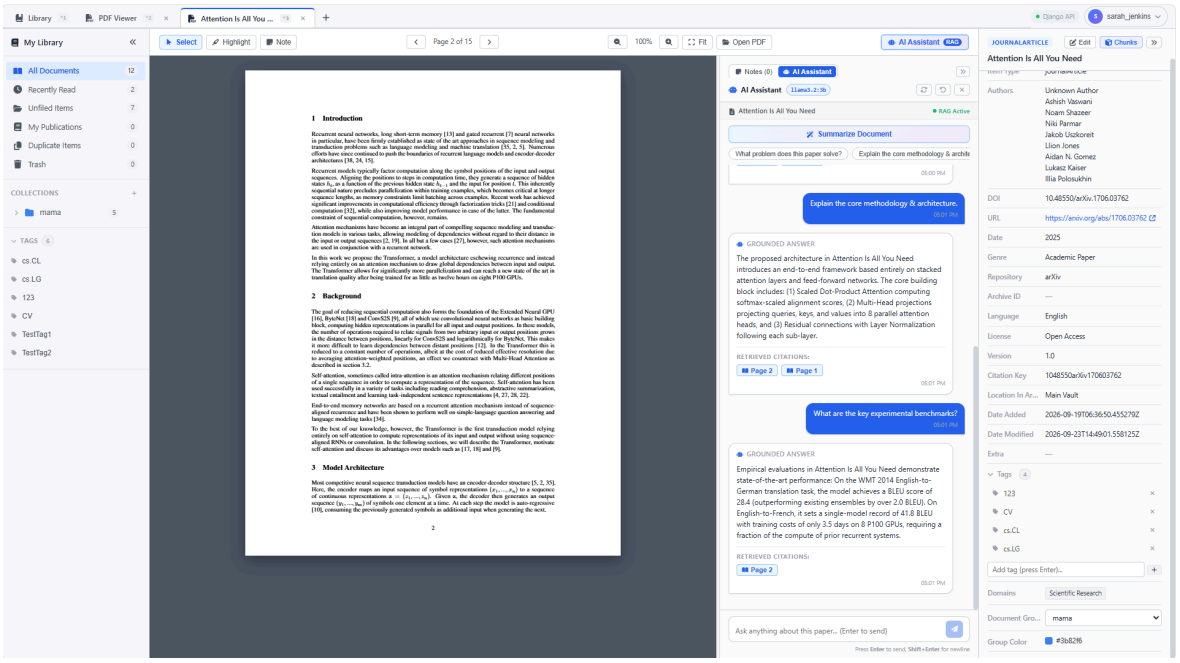
4.6.2. Các màn hình chính

Hệ thống cung cấp các giao diện tương ứng với những chức năng nghiệp vụ chính, hỗ trợ người dùng thêm tài liệu, đọc nội dung PDF và tra cứu thông tin thông qua trợ lý AI.



Hình 4.8. Giao diện tải lên PDF và xem trước metadata.

Giao diện tải lên PDF cho phép người dùng lựa chọn tài liệu và kiểm tra thông tin được trích xuất trước khi thêm tài liệu vào thư viện. Người dùng có thể rà soát và điều chỉnh thông tin trước khi xác nhận.



Hình 4.9. Giao diện trợ lý AI và các nguồn trích dẫn.

Trợ lý AI cho phép người dùng đặt câu hỏi liên quan đến tài liệu đang nghiên cứu. Câu trả lời được hiển thị cùng các nguồn trích dẫn tương ứng, giúp người dùng xác định vị trí nội dung được sử dụng làm căn cứ và thuận tiện kiểm tra lại thông tin trong tài liệu gốc.

Các giao diện trên hỗ trợ quy trình sử dụng chính của hệ thống: người dùng thêm tài liệu vào thư viện, đọc nội dung PDF và sử dụng trợ lý AI để tra cứu thông tin dựa trên tài liệu. Các chức năng tra cứu DOI và kiểm tra chunk vẫn có thể được mô tả trong phần chức năng tương ứng mà không cần trình bày thành hình minh họa riêng.

4.7 Cài đặt các chức năng chính

4.7.1. Xác thực và quản lý phiên đăng nhập

Hệ thống sử dụng Django REST Framework kết hợp Simple JWT để xác thực người dùng bằng access token và refresh token. Người dùng có thể đăng ký, đăng nhập bằng tên tài khoản hoặc email, đồng thời tự động làm mới phiên khi access token hết hạn thông qua Axios interceptor.

Khi đăng xuất, refresh token được đưa vào danh sách thu hồi (blacklist). Theo cấu hình hiện tại, access token có thời hạn một giờ và refresh token có thời hạn bảy ngày. Các chức năng xác thực đã được kiểm thử thông qua sáu bài kiểm thử tự động theo kết quả ghi nhận trong dự án.

4.7.2. Tải lên tài liệu và trích xuất metadata

Hệ thống cho phép người dùng tải lên tài liệu PDF với dung lượng tối đa 50 MB. Tệp được kiểm tra phần mở rộng và chữ ký định dạng trước khi xử lý.

PyMuPDF được sử dụng để trích xuất thông tin ban đầu như tiêu đề, tác giả và năm xuất bản. Hệ thống nhận diện DOI và arXiv ID để tra cứu metadata từ Crossref, arXiv và OpenAlex. Người dùng có thể xem trước, chỉnh sửa thông tin trước khi lưu tài liệu vào PostgreSQL và khởi tạo quá trình lập chỉ mục RAG.

4.7.3. Tổ chức, tìm kiếm và lọc tài liệu

Hệ thống hỗ trợ tổ chức tài liệu theo bộ sưu tập phân cấp, thẻ từ khóa và lĩnh vực nghiên cứu. Một tài liệu có thể thuộc nhiều bộ sưu tập, giúp người dùng linh hoạt phân loại thư viện.

Giao diện cung cấp chức năng tìm kiếm theo tiêu đề, tác giả, thẻ và lĩnh vực; lọc theo danh mục, bộ sưu tập; đồng thời sắp xếp theo các tiêu chí được hỗ trợ. Hiện tại, các thao tác tìm kiếm và lọc chủ yếu được thực hiện phía máy khách, chưa có tìm kiếm toàn văn hoặc phân trang phía máy chủ.

4.7.4. Đọc PDF và quản lý chú thích

Trình đọc PDF sử dụng PDF.js với hai lớp Canvas và TextLayer, hỗ trợ hiển thị tài liệu, lựa chọn và sao chép văn bản. Người dùng có thể đánh dấu văn bản bằng nhiều màu, tạo ghi chú và quản lý chú thích trên giao diện.

Các chú thích được lưu trong cơ sở dữ liệu cùng thông tin trang, tọa độ và nội dung liên quan. Trình đọc cũng hỗ trợ điều hướng đến trang chứa dẫn chứng khi người dùng nhấn vào trích dẫn từ trợ lý AI. Tuy nhiên, tọa độ chú thích hiện được lưu theo pixel nên vị trí có thể sai lệch khi thay đổi kích thước hoặc mức thu phóng.

4.8. Cài đặt và tích hợp RAG

Hệ thống tích hợp pipeline RAG gồm các bước trích xuất văn bản từ tài liệu PDF, phân mảnh văn bản, tạo embedding, lưu trữ và truy xuất các đoạn liên quan, sau đó sử dụng mô hình ngôn ngữ để sinh câu trả lời kèm nguồn tham chiếu.

Các phương pháp và tham số trong từng bước hiện đang được đánh giá thực nghiệm nhằm lựa chọn cấu hình phù hợp. Cấu hình đang triển khai được sử dụng làm baseline ban đầu để so sánh với các phương án khác, chưa phải cấu hình tối ưu cuối cùng. Vì vậy, các công nghệ và tham số cụ thể sẽ được xác định chính thức sau khi hoàn thành quá trình đánh giá.

Lưu ý: Hình 4.2 và Hình 4.4 minh họa cấu hình baseline ban đầu sử dụng mô hình nhúng MiniLM và phương pháp phân mảnh section_overlap trước khi hệ thống được nâng cấp lên mô hình e5-small-v2 và chiến lược chia đoạn phân cấp (hierarchical chunking).

4.9 Hạn chế của hệ thống

Hệ thống hiện còn một số hạn chế:

1. **Chia sẻ và cộng tác**: Backend có các thành phần phân quyền, nhưng giao diện chia sẻ và quản lý cộng tác viên chưa hoàn thiện.
2. **Tìm kiếm tài liệu**: Tìm kiếm và lọc chủ yếu thực hiện phía máy khách; chưa có tìm kiếm toàn văn và phân trang phía máy chủ.
3. **Đặt lại mật khẩu**: Chưa hoàn thiện quy trình tích hợp API, dịch vụ email và giao diện người dùng.
4. **Chú thích PDF**: Tọa độ lưu theo pixel có thể sai lệch khi thay đổi kích thước hoặc mức thu phóng.
5. **Dịch vụ AI**: Khả năng sinh câu trả lời phụ thuộc vào Ollama và tài nguyên máy chạy ứng dụng. Cơ chế dự phòng cung cấp trích đoạn liên quan nhưng không thay thế hoàn toàn khả năng tổng hợp của LLM.
6. **Chất lượng RAG**: Hiệu quả phụ thuộc vào nhiều thành phần của pipeline và cần được đánh giá bằng thực nghiệm; cấu hình đang triển khai không mặc nhiên là cấu hình tối ưu.

Mô hình ngôn ngữ được hướng dẫn chỉ dùng ngữ cảnh đã truy xuất, nhưng prompt cũng cho phép tổng hợp thông tin liên quan nhất khi ngữ cảnh không chứa câu trả lời trực tiếp, nên hệ thống không bảo đảm câu trả lời hoàn toàn dựa trên tài liệu. Các huy hiệu trích dẫn trang cho biết những mục được truy xuất, không xác nhận rằng câu trả lời được các mục đó hỗ trợ. Độ trung thực của câu trả lời chưa được đánh giá định lượng trong báo cáo này.

CHƯƠNG 5. KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

Chương này trình bày kết quả của ba thí nghiệm thành phần đã thực hiện (RQ1–RQ3): trích xuất văn bản từ PDF, chia đoạn văn bản và mô hình embedding. Kết quả được báo cáo bằng thống kê mô tả, tức là giá trị đo được và mức chênh lệch quan sát được trong điều kiện thực nghiệm. Chương không sử dụng kiểm định giả thuyết thống kê nên không đưa ra kết luận về ý nghĩa thống kê hay tính vượt trội tuyệt đối của bất kỳ phương pháp nào. Phần cuối chương nêu hiện trạng của RQ4–RQ6, các giới hạn của nghiên cứu và định hướng kiểm chứng tiếp theo.

5.1. Phạm vi và đặc trưng dữ liệu thực nghiệm

5.1.1. Bộ dữ liệu QASPER

QASPER v0.3 gồm 1.585 bài báo và 5.049 câu hỏi. Số lượng theo từng tập con được trình bày ở Bảng 5.1.

Tập	**Số bài báo**	**Số câu hỏi**
Train	888	2.593
Dev	281	1.005
Test	416	1.451
Tổng	**1.585**	**5.049**

Bảng 5.1. Thống kê bộ dữ liệu QASPER

Các câu hỏi được phân thành bốn loại như trong Bảng 5.2.

Loại câu hỏi	Số lượng	Tỷ lệ
Extractive	2.878	57,00%
Abstractive	1.011	20,02%
Yes/No	710	14,06%
Unanswerable	450	8,91%

Bảng 5.2. Phân bố loại câu hỏi trong QASPER

Phân tích khám phá dữ liệu (EDA), gồm trực quan hóa ở Hình 5.1, cho thấy các đặc trưng sau:

- **Độ dài bài báo:** trong 1.584 bài báo có số đo độ dài hợp lệ, trung bình mỗi bài có 3.575 từ, trung vị 3.401 từ và phân vị 95 là 6.707 từ.
- **Cấu trúc mục:** tập EDA cấp mục có 21.909 mục, trung bình 13,83 mục mỗi bài. Độ dài trung bình của một mục là 258,5 từ và phân vị 95 là 706 từ.
- **Độ dài câu hỏi và bằng chứng:** câu hỏi trung bình dài 8,14 từ, còn bằng chứng tham chiếu dài khoảng 175,5 từ, tức gấp khoảng 21,6 lần.
- **Độ tương đồng từ vựng:** độ tương đồng Jaccard trung bình giữa câu hỏi và bằng chứng là 1,61% khi tính trên toàn bộ câu hỏi, và 2,59% khi chỉ tính trên các câu hỏi có bằng chứng dạng văn bản. Hai giá trị này có mẫu số khác nhau nên không thay thế cho nhau được.
- **Bằng chứng nhiều đoạn:** trong 4.303 câu hỏi có bản ghi bằng chứng liên quan, 1.891 câu (khoảng 43,95%) có bằng chứng trải trên nhiều đoạn văn bản.

Chỉ số "expert agreement solvable": được ghi nhận ở mức 87,01%. Báo cáo chỉ nêu lại giá trị này như một thống kê của bộ dữ liệu và không diễn giải nó là độ đồng thuận giữa những người gán nhãn.

5.1.2. Ý nghĩa của các đặc trưng dữ liệu đối với thiết kế thực nghiệm

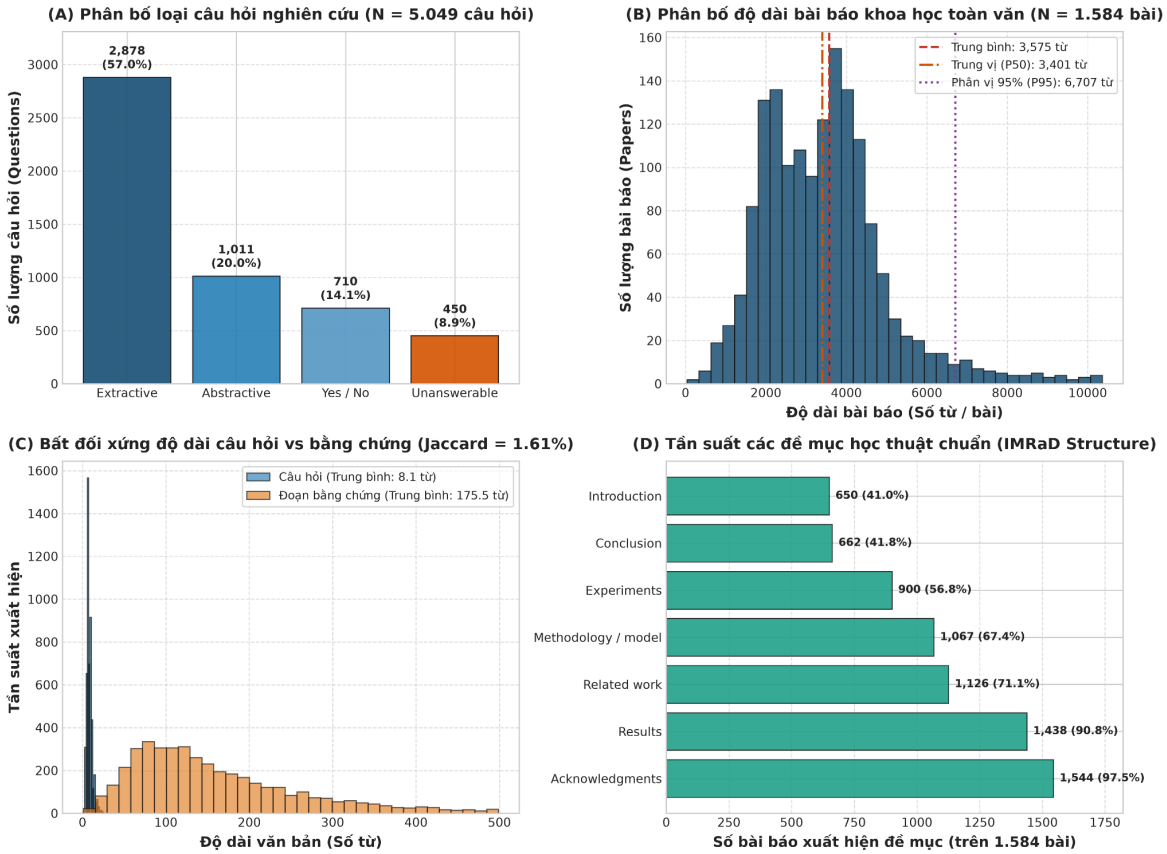
Các đặc trưng trên gợi ý bốn vấn đề cần xem xét trong pipeline RAG:

1. Bài báo và nhiều mục có thể dài hơn cửa sổ đầu vào thông thường của mô hình embedding, nên cần chia đoạn.

2. Câu hỏi ngắn trong khi bằng chứng dài hơn nhiều lần, nên việc định vị đúng đoạn văn bản phụ thuộc vào cách chia đoạn và cách biểu diễn.

3. Mức trùng lặp từ vựng giữa câu hỏi và bằng chứng thấp, nên cần so sánh truy xuất từ khóa (BM25) với truy xuất bằng embedding.

4. Một tỷ lệ đáng kể câu hỏi có bằng chứng trải trên nhiều đoạn, nên việc mở rộng ngữ cảnh theo cấu trúc phân cấp là hướng đáng khảo sát.



Hình 5.1. Một số thông số về dataset QASPER

5.1.3. Các tập con dùng trong từng thí nghiệm

Thí nghiệm	Bài báo	Câu hỏi / đoạn văn bản	Cấu hình đáng chú ý
RQ1 – Trích xuất PDF	47 bài Dev có PDF cục bộ, cùng 4 bài thử nghiệm kỹ thuật	127 câu hỏi khả giải	4 luồng CPU; embedding hạ nguồn intfloat/e5-small-v2
RQ2 – Chia đoạn (mở rộng)	47	127 câu hỏi khả giải	Ngân sách ngữ cảnh 1.600 token; $\tau = 0{,}50$ (chính), $\tau = 0{,}30$ (độ nhạy)
RQ3 – Embedding	207 (48 Dev + 159 held-out)	615 câu hỏi khả giải; 5.207 đoạn	$\tau = 0{,}55$

Bảng 5.3. Tập dữ liệu sử dụng trong từng thí nghiệm

Số câu hỏi của RQ1 được xác định như sau: ban đầu có 132 câu hỏi thuộc 48 bài Dev. Hai câu hỏi liên quan đến bài báo không có PDF (arXiv:1802.00396) và ba câu hỏi không thể trả lời bị loại, nên còn $132 - 2 - 3 = 127$ câu. Bốn bài thử nghiệm kỹ thuật bổ sung là *Attention Is All You Need*, ResNet, LoRA và RAG.

Thư mục PDF cục bộ có 61 tệp tải từ arXiv. RQ1 dùng 51 tệp: 47 bài thuộc tập Dev của QASPER (bài arXiv:1802.00396 không tải được nên tập Dev 48 bài còn 47) và 4 bài kỹ thuật bổ sung (Attention Is All You Need, ResNet, LoRA, RAG). 10 tệp còn lại không dùng trong các bảng kết quả. RQ3 không trích xuất từ PDF mà dùng văn bản có cấu trúc của QASPER (48 bài Dev từ tập Validation và 159 bài từ tập Train), để sai số trích xuất PDF không ảnh hưởng đến so sánh giữa các mô hình embedding.

5.2. RQ1 – Đánh giá phương pháp trích xuất văn bản từ PDF

5.2.1. Thiết lập

Thí nghiệm so sánh năm bộ trích xuất cục bộ (`pymupdf_plain`, `pymupdf_layout`, `pypdf`, `pdfminer.six`, `pdfplumber`) trên 47 PDF thuộc tập Dev và

127 câu hỏi khả giải, cùng bốn bài thử nghiệm kỹ thuật. Thí nghiệm chạy trên CPU AMD Ryzen 5 5600 với bốn luồng (`torch.set_num_threads(4)`). Mô hình embedding hạ nguồn là `intfloat/e5-small-v2`. Baseline là `pymupdf_plain`. GROBID được đưa vào thiết kế ban đầu nhưng không chạy được do máy chủ dịch vụ không phản hồi, nên được ghi nhận là *không khả dụng* chứ không phải là phương pháp đạt điểm bằng 0.

5.2.2. Kết quả

Công cụ	Evidence Coverage	Heading F1	Reading Order	Độ trễ (ms/trang)	nDCG@10 hạ nguồn
`pymupdf_plain` (baseline)	37,59%	0,00%	0,9894	10,19	**0,5274**
`pymupdf_layout`	33,16%	**48,01%**	0,9894	26,16	0,5100
`pypdf`	29,61%	0,00%	0,9787	61,72	0,5174
`pdfminer.six`	35,82%	0,00%	0,9713	107,10	0,5131
`pdfplumber`	9,86%	0,00%	0,5319	195,36	0,3769
GROBID	—	—	—	—	Không khả dụng

Bảng 5.4. Kết quả đánh giá các bộ trích xuất văn bản PDF (47 bài Dev)

5.2.3. Thảo luận

`pymupdf_plain` có nDCG@10 hạ nguồn cao nhất (0,5274) và độ trễ thấp nhất (10,19 ms/trang). Hai bộ trích xuất dựa trên PyMuPDF nhanh hơn rõ rệt so với các lựa chọn còn lại: `pymupdf_layout` mất 26,16 ms/trang, trong khi `pypdf`, `pdfminer.six` và `pdfplumber` lần lượt mất 61,72, 107,10 và 195,36 ms/trang. Bốn bộ trích xuất đầu bảng (`pymupdf_plain`, `pymupdf_layout`, `pypdf`, `pdfminer.six`) có nDCG@10 nằm trong khoảng 0,51–0,53, tức chênh lệch quan sát được giữa chúng khá nhỏ. `pdfplumber` thấp hơn rõ rệt ở cả Reading Order (0,5319) và nDCG@10 (0,3769) trong thiết lập này.

Về tỷ lệ khớp ký tự, pymupdf_plain đạt 33,09%, pymupdf_layout 32,78%, pypdf 32,28%, pdfminer.six 33,44% và pdfplumber chỉ 3,99%. Bộ nhớ đỉnh của tiến trình nằm trong khoảng 1.164,9–1.286,2 MB ở cả năm công cụ (pymupdf_plain 1.228,7 MB; pymupdf_layout 1.164,9 MB; pypdf 1.286,2 MB; pdfminer.six 1.169,2 MB; pdfplumber 1.236,4 MB). GROBID không có số liệu do không khả dụng trong môi trường thực nghiệm.

Chỉ `pymupdf_layout` cho Heading F1 khác 0 (48,01%). Điểm 0,00% ở các bộ còn lại phản ánh việc các adapter hiện tại không xuất thông tin tiêu đề, chứ không chứng minh các thư viện gốc không thể nhận diện tiêu đề.

Evidence Coverage so khớp văn bản trích xuất từ PDF với chuỗi bằng chứng tham chiếu. Chỉ số này có thể bị ảnh hưởng bởi sự khác biệt giữa văn bản trong PDF và văn bản nguồn (ví dụ công thức, trích dẫn, ký tự đặc biệt). Vì vậy, không nên diễn giải nó là tỷ lệ nội dung bị mất.

5.2.4. Quyết định lựa chọn

Pipeline hiện tại sử dụng `pymupdf_layout`. Bộ này không đạt nDCG@10 hạ nguồn cao nhất, nhưng cung cấp thông tin tiêu đề, là dữ liệu đầu vào cần thiết cho chia đoạn theo mục và chia đoạn phân cấp ở bước sau. Đây là sự đánh đổi có chủ đích giữa điểm truy xuất quan sát được và khả năng bảo toàn cấu trúc tài liệu. Quyết định này phù hợp với dữ liệu và yêu cầu của hệ thống hiện tại, không được xem là tối ưu trong mọi trường hợp.

5.3. RQ2 – Đánh giá chiến lược chia đoạn văn bản (Chunking)

Phần này trình bày theo trình tự: một khảo sát sơ bộ, các câu hỏi được đặt ra từ khảo sát đó, một đánh giá mở rộng có cấu hình được ghi nhận rõ ràng, và quyết định kỹ thuật rút ra.

5.3.1. Khảo sát sơ bộ trên FiQA và QASPER

Khảo sát sơ bộ so sánh ba phương pháp chia đoạn là Fixed Size, Recursive và Semantic trên hai bộ dữ liệu FiQA và QASPER, với các chỉ số tại k = 5.

Kích thước chia đoạn dựa trên số lượng ký tự đạt 500 ký tự ở cài đặt mặc định đối với Recursive Chunker và 550 ký tự đối với Fixed Size Chunker, trong khi Semantic Chunker thay đổi độ dài linh hoạt theo ranh giới khoảng cách ngữ nghĩa.

Độ đè ngữ cảnh (overlap) giữa các đoạn liền kề đạt 50 ký tự đối với Recursive Chunker và 150 ký tự đối với Fixed Size Chunker, riêng Semantic Chunker có mức đè bằng 0 do phương pháp này ngắt đoạn hoàn toàn dựa vào ranh giới chuyển đổi ngữ nghĩa.

Mô hình embedding e5-small-v2 sẽ được sử dụng, còn phép đo độ dài đoạn ở hai phương pháp Recursive và Fixed Size sử dụng hàm len mặc định của Python nên đơn vị đo độ dài hoàn toàn dựa trên số lượng ký tự chứ không phải số lượng token từ tokenizer.

Ngưỡng phân tách ngữ nghĩa trong Semantic Chunker được thiết lập theo kiểu percentile với giá trị 85, đồng nghĩa với việc đoạn văn sẽ bị ngắt khi độ tương đồng giữa các câu giảm xuống thuộc nhóm 15% thấp nhất.

Số lượng truy vấn và tổng dung lượng bộ nhớ ngữ cảnh nạp vào hệ thống không xuất hiện trong đoạn mã nguồn này vì hai thông số trên thuộc về kịch bản đánh giá phía sau như số lượng Top-*k* đoạn văn được truy xuất.

Chỉ số	Fixed Size	Recursive	Semantic
Precision@5	0,048	**0,049**	**0,049**
Recall@5	0,133	**0,143**	0,141
F1@5	0,064	**0,067**	0,066
nDCG@5	0,109	**0,111**	0,106

Bảng 5.5. Kết quả khảo sát sơ bộ trên QASPER (k = 5)

Chỉ số	Fixed Size	Recursive	Semantic
Precision@5	**0,202**	0,181	0,173
Recall@5	**0,439**	0,399	0,382
F1@5	**0,251**	0,226	0,216
nDCG@5	**0,423**	0,382	0,368

Bảng 5.6. Kết quả khảo sát sơ bộ trên FiQA (k = 5)

Thứ hạng có sự đảo chiều trên bộ dữ liệu mới khi Recursive vươn lên đứng đầu ở mọi chỉ số được báo cáo. Semantic nhìn chung đứng thứ hai và Fixed Size tụt xuống thứ ba, trừ trường hợp Precision@5 khi Recursive và Semantic bằng nhau (cùng đạt 0,049).

Trên bộ dữ liệu mới, nDCG@5 của Recursive là 0,111 so với 0,109 của Fixed Size và 0,106 của Semantic, cao hơn lần lượt khoảng 1,8% và 4,7% tương đối. Mức chênh lệch này nhỏ hơn đáng kể so với con số 15% trên FiQA. Mặt bằng điểm tuyệt đối trên bộ dữ liệu mới khá thấp (nDCG@5 quanh mức 0,11), tương đồng với QASPER và thấp hơn nhiều so với FiQA (nDCG@5 đạt từ 0,368 đến 0,423).

Khảo sát sơ bộ không báo cáo kiểm định thống kê.

5.3.2. Động lực và thiết kế đánh giá mở rộng

Các quan sát chính từ khảo sát sơ bộ cho thấy một xu hướng đáng chú ý nhưng chưa đủ thông tin cấu hình để diễn giải chắc chắn, dẫn đến việc nhóm nghiên cứu nêu ra một số giả thuyết chưa được kiểm chứng.

Đầu tiên là khối lượng ngữ cảnh không đồng đều, khi các đoạn Fixed Size dài khoảng 550 token có thể trả về khoảng 2.750 token ở năm kết quả đầu tiên, trong khi Semantic chỉ trả về khoảng 600–1.200 token, khiến phép so sánh phản ánh một phần lượng ngữ cảnh được trả về chứ không thuần túy là chất lượng chia đoạn. Bên cạnh đó, hiệu ứng chồng lấp có thể đã giúp giữ lại bằng chứng nằm gần ranh giới giữa các đoạn.

Một giả thuyết khác là sự phụ thuộc vào mô hình embedding, khi intfloat/e5-small-v2 có thể chưa xác định tốt ranh giới ngữ nghĩa trên văn bản chuyên ngành, dù điều này chưa được kiểm tra bằng cách thay đổi mô hình embedding trong cùng điều kiện. Cuối cùng, mức điểm QASPER thấp có thể liên quan đến cách xây dựng corpus, cách gán nhãn liên quan hoặc mức độ chi tiết khi đánh giá, nhưng chưa thể chẩn đoán chắc chắn do thiếu tài liệu về thiết lập ban đầu.

Câu hỏi trung tâm đặt ra là liệu Fixed Size có thực sự là chiến lược chia đoạn tốt hơn, hay lợi thế quan sát được một phần xuất phát từ điều kiện đánh giá ban đầu. Khảo sát sơ bộ chỉ mang tính thăm dò và không mang hàm ý cho rằng kết quả trước đó là sai, mà chính nó đóng vai trò tiền đề dẫn đến việc thiết kế một thí nghiệm có cấu hình được ghi nhận rõ ràng hơn trên QASPER.

Thí nghiệm mở rộng được tiến hành trên 47 bài báo và 127 câu hỏi khả giải, sử dụng văn bản trích xuất bằng pymupdf_layout, mô hình embedding intfloat/e5-small-v2 và độ tương đồng cosine chính xác dựa trên NumPy BLAS FP32. Trong thiết lập này, ngân sách ngữ cảnh cố định được đặt ở mức 1.600 token. Một đoạn được xem là liên quan khi tỷ lệ từ nội dung của bằng chứng tham chiếu mà đoạn đó bao phủ đạt ngưỡng τ sau khi loại bỏ từ dừng, với ngưỡng chính là τ=0,50 và ngưỡng phụ τ=0,30 được dùng để đánh giá độ nhạy. Tám chiến lược chia đoạn được đưa vào so sánh bao gồm:

- fixed_size: 400 token, không chồng lấp.
- fixed_size_overlap: 400 token, chồng lấp 80 token (bước trượt danh nghĩa 320 token).
- semantic: tách theo ngữ nghĩa ở mức câu, tối đa 400 token.
- section: mỗi mục là một đoạn, không giới hạn độ dài.
- section_token: chia theo mục với giới hạn khoảng 400 token (được hiện thực bằng khoảng 1.600 ký tự).
- section_overlap: chia theo mục, tối đa 400 token, chồng lấp 80 token.
- hierarchical: truy xuất các đoạn con 200 token (chồng lấp 40 token), sau đó mở rộng sang mục cha tương ứng để làm ngữ cảnh.

- hierarchical_child: sử dụng cùng các đoạn con 200 token nhưng giữ nguyên và không mở rộng sang mục cha.

5.3.3. Kết quả đánh giá mở rộng

Chiến lược	Số đoạn	Tỷ lệ cắt cụt	nDCG @10	nDCG @4	Recall @20	MRR@ 10	Bao phủ ngân sách ngữ cảnh (%)
fixed_size	893	0,00%	0,5654	0,4443	0,9586	0,5310	78,74
fixed_size_overla p	1.109	0,00%	0,5385	0,4336	0,9452	0,5269	81,10
semantic	1.907	0,21%	0,4856	0,3904	0,8680	0,4983	80,31
section	907	23,70%	0,5795	0,4473	0,9753	0,5456	74,80
section_token	1.498	0,73%	0,5359	0,4475	0,9234	0,5520	80,31
section_overlap	1.591	0,63%	0,5409	0,4569	0,9255	0,5737	76,38
hierarchical	**2.618**	**0,00%**	**0,6880**	**0,5933**	**0,9873**	**0,6468**	**81,10**
hierarchical_chil d	2.618	0,00%	0,4473	0,3791	0,7781	0,4816	80,31

Bảng 5.7. Kết quả tám chiến lược chia đoạn trên QASPER (47 bài, 127 câu hỏi, τ = 0,50)

Ghi chú: tỷ lệ cắt cụt là tỷ lệ đoạn vượt giới hạn đầu vào của mô hình embedding.

Chiến lược	nDCG @10 (τ = 0,50)	nDCG @10 (τ = 0,30)	Recall @20 (τ = 0,50)	Recall @20 (τ = 0,30)
fixed_size	0,5654	0,6252	0,9586	0,9685
fixed_size_overlap	0,5385	0,6123	0,9452	0,9588
semantic	0,4856	0,5612	0,8680	0,8921
section	0,5795	0,6000	0,9753	0,9802
section_token	0,5359	0,6081	0,9234	0,9412
section_overlap	0,5409	0,6155	0,9255	0,9438
hierarchical	**0,6880**	**0,7340**	**0,9873**	**0,9912**
hierarchical_child	0,4473	0,4617	0,7781	0,7950

Bảng 5.8. Phân tích độ nhạy theo ngưỡng liên quan τ (47 bài, 127 câu hỏi)

Khi hạ ngưỡng từ τ = 0,50 xuống τ = 0,30, hierarchical vẫn đứng đầu về nDCG@10 (0,6880 → 0,7340) và hierarchical_child vẫn thấp nhất. Một số cặp chiến lược đổi thứ hạng: fixed_size (0,6252) vượt section (0,6000); fixed_size_overlap (0,5801) vượt section_overlap (0,5440); section_token (0,5486) vượt section_overlap (0,5440). Vì vậy thứ tự giữa các chiến lược ở giữa bảng nhạy với ngưỡng liên quan.

5.3.4. Thảo luận và quyết định sử dụng hierarchical chunking

Diễn giải kết quả: Trong cấu hình đã khảo sát, `hierarchical` có giá trị quan sát cao nhất ở cả bốn chỉ số truy xuất (nDCG@10 = 0,6880; nDCG@4 = 0,5933; Recall@20 = 0,9873; MRR@10 = 0,6468). `fixed_size` vẫn đạt kết quả khá tốt (nDCG@10 = 0,5654; Recall@20 = 0,9586), còn `semantic` thấp hơn trong cấu hình này (nDCG@10 = 0,4856; Recall@20 = 0,8680).

`section` đạt nDCG@10 = 0,5795, cao thứ hai trong bảng. Tuy nhiên 23,70% số đoạn của chiến lược này vượt giới hạn đầu vào của mô hình embedding và có nguy cơ bị cắt cụt. Đây là rủi ro vận hành, vì phần bị cắt không được biểu diễn trong vector dù chỉ số truy xuất nhìn chung có vẻ tốt.

`hierarchical_child` (chỉ truy xuất đoạn con, không mở rộng sang mục cha) đạt nDCG@10 = 0,4473 và Recall@20 = 0,7781, thấp hơn nhiều so với `hierarchical` có mở rộng (0,6880 và 0,9873). Điều này cho thấy việc mở rộng sang ngữ cảnh cha đóng góp đáng kể vào điểm số trong quy trình đánh giá hiện tại.

Độ nhạy với ngưỡng liên quan: Khi hạ ngưỡng xuống $\tau = 0{,}30$, `hierarchical` vẫn đạt nDCG@10 cao nhất (0,7340) và `hierarchical_child` vẫn thấp nhất (0,4617). Thứ tự của các chiến lược ở giữa có thay đổi: chẳng hạn `fixed_size` (0,6252) đứng trên `section` (0,6000) ở $\tau = 0{,}30$, ngược với thứ tự ở $\tau = 0{,}50$. Bảng 5.8 tổng hợp kết quả so sánh giữa hai ngưỡng. Vì vậy, chỉ có thể nói vị trí đầu và cuối bảng ổn định giữa hai ngưỡng; các chênh lệch nhỏ ở giữa bảng nên được diễn giải thận trọng.

Lưu ý quan trọng về cách gán nhãn liên quan: Nhãn liên quan dựa trên mức bao phủ từ vựng của chuỗi bằng chứng. Một mục cha dài hơn đoạn con, nên có nhiều cơ hội chứa chuỗi bằng chứng hơn. Do đó điểm số cao của `hierarchical` có thể phản ánh một phần cách thức mà thước đo tương tác với việc mở rộng ngữ cảnh. Kết quả này vẫn có giá trị: nó cho thấy mức bao phủ bằng chứng tốt hơn trong ngân sách ngữ cảnh 1.600 token theo quy trình đánh giá truy xuất hiện tại. Tuy nhiên độ chính xác và tính trung thực của câu trả lời cuối cùng chỉ có thể kết luận sau khi đánh giá toàn bộ pipeline sinh câu trả lời.

Thay đổi thứ hạng giữa hai giai đoạn thực nghiệm: Ở khảo sát sơ bộ, Fixed Size đứng đầu trong ba phương pháp trên FiQA và QASPER. Ở thí nghiệm mở rộng, `hierarchical` đứng đầu trong tám phương pháp trên QASPER. Hai kết quả này là hai nhóm quan sát riêng, và không nên xem sự thay đổi thứ hạng là do một yếu tố đơn lẻ gây ra, vì:

- Thí nghiệm mở rộng có ngân sách ngữ cảnh 1.600 token được ghi nhận rõ, số chiến lược nhiều hơn và bộ chỉ số khác (nDCG@10, nDCG@4, Recall@20, MRR@10 thay vì chỉ số tại k = 5);
- Cấu hình khảo sát sơ bộ không đủ tài liệu để tiến hành so sánh có kiểm soát từng biến một;
- Các giá trị nDCG@5 khoảng 0,12 trên QASPER ở giai đoạn đầu và nDCG@10 khoảng 0,5 ở giai đoạn sau không phải là cùng một chỉ số trong cùng điều kiện, nên không được so sánh trực tiếp.

Do đó, báo cáo không kết luận rằng việc mở rộng corpus là nguyên nhân duy nhất làm đổi thứ hạng, cũng không kết luận pipeline sơ bộ có lỗi. Diễn biến phù hợp nhất để mô tả là: một kết quả thăm dò ban đầu, sau đó là một thí nghiệm chẩn đoán mở rộng được kiểm soát chặt chẽ hơn.

Quyết định kỹ thuật: Căn cứ vào kết quả mở rộng, nhóm điều chỉnh pipeline ứng dụng để hỗ trợ truy xuất phân cấp. Kiến trúc dự kiến gồm:

1. Lưu định danh của mục cha và định danh của đoạn con;
2. Chia các mục dài thành đoạn con đủ nhỏ để embedding;
3. Truy xuất và xếp hạng các đoạn con;
4. Mở rộng các đoạn con được truy xuất sang ngữ cảnh cha, hoặc một phần ngữ cảnh cha có giới hạn kích thước, trước khi đưa vào bước sinh câu trả lời;
5. Giữ đủ siêu dữ liệu để truy vết ngữ cảnh về tài liệu và mục nguồn;
6. Đánh giá lại bản triển khai thực tế sau khi hoàn thành.

Cấu hình tốt nhất quan sát được trong benchmark là đoạn con 200 token với chồng lấp 40. Cấu hình triển khai thực tế của ứng dụng có thể khác. Một phép kiểm tra hồi quy trên pipeline ứng dụng đã được thực hiện (mục 5.3.5), nhưng các điểm số của phép kiểm tra này khác với benchmark RQ2 và chưa tương đương với một đánh giá đầu cuối.

5.3.5. Kiểm chứng trên pipeline ứng dụng (production parity)

Sau khi điều chỉnh ứng dụng để hỗ trợ truy xuất phân cấp, nhóm chạy một bộ kiểm thử hồi quy để so sánh hàm search_hierarchical của pipeline ứng dụng với

chiến lược section_overlap. Bộ kiểm thử dùng 47 bài Dev, 127 câu hỏi, ngân sách ngữ cảnh 1.600 token và ngưỡng liên quan $\tau = 0{,}50$.

Chiến lược	nDCG @10	nDCG @4	Recall @20	MRR @10	P50 (ms)	P95 (ms)	Số đoạn (vector)	Số mục cha
`section_overlap`	0,4743	0,4569	0,5473	0,5543	31,74	43,40	1.591	0
`hierarchical`	0,5049	0,5139	0,5840	0,5641	31,76	42,67	2.618	907

Bảng 5.9. So sánh section_overlap và hierarchical trên pipeline ứng dụng (47 bài, 127 câu hỏi, τ = 0,50)

Các quan sát chính:

Giá trị nDCG@4 của section_overlap giống nhau ở hai bảng (0,4569) là kết quả tự nhiên, không phải do sao chép. Bốn đoạn xếp đầu của section_overlap dài khoảng 980 token (4 × 245,7 token trung bình), luôn nằm trọn trong ngân sách ngữ cảnh 1.600 token ở cả hai khung đánh giá. Ở k = 10 và k = 20, khung đánh giá của ứng dụng chỉ tính các đoạn thực sự được nạp vào ngữ cảnh theo ngân sách này, nên nDCG@10 và Recall@20 thấp hơn so với khi xếp hạng toàn bộ danh sách.

Do danh sách xếp hạng ở khung ứng dụng bị cắt theo ngân sách 1.600 token (trung bình 7,43 đoạn với section_overlap và 5,89 mục cha với hierarchical), nDCG@10 và Recall@20 trong bảng này tính trên danh sách ngắn hơn và không tương đương với các chỉ số cùng tên ở Bảng 5.7; chỉ nên so sánh giữa hai cấu hình trong cùng bảng.

- **Chất lượng truy xuất:** `hierarchical` có giá trị quan sát cao hơn ở cả bốn chỉ số. nDCG@4 tăng từ 0,4569 lên 0,5139 (+0,0570 tuyệt đối, khoảng +12,5% tương đối), nDCG@10 tăng từ 0,4743 lên 0,5049 (+0,0306), Recall@20 tăng từ 0,5473 lên 0,5840 (+0,0367) và MRR@10 tăng từ 0,5543 lên 0,5641 (+0,0098).

- **Độ trễ:** độ trễ trung vị gần như trùng nhau (31,76 ms so với 31,74 ms); P95 là 42,67 ms so với 43,40 ms. Hai chiến lược có độ trễ truy vấn tương đương trong lần đo này.
- **Chỉ mục:** 47 bài tạo ra 2.618 vector đoạn con trong collection chính và 907 mục cha lưu trong collection đi kèm, không có vector. Số đoạn con khớp với số đoạn của hierarchical ở Bảng 5.7.

Phạm vi diễn giải: Xu hướng cho thấy hierarchical cao hơn section_overlap giống với thí nghiệm RQ2. Tuy nhiên, độ lớn của các điểm số khác rõ so với Bảng 5.7, đặc biệt ở Recall@20. Hai thí nghiệm dùng bộ công cụ đánh giá khác nhau, nên không so trực tiếp được với nhau và mức khác biệt này chưa được lý giải trong báo cáo. Cụ thể, benchmark RQ2 tính toán các chỉ số xếp hạng (nDCG@10, Recall@20) trên toàn bộ danh sách ứng viên thu nạp ban đầu (danh sách đủ 20 mục), trong khi pipeline production đánh giá trực tiếp trên danh sách đoạn văn trả về đã bị chặn trần bởi ngân sách 1.600 token (thực tế chỉ chứa trung bình 5,9 mục cha hoặc 7,4 đoạn gối đầu, trung vị từ 6 đến 7 mục), khiến độ dài danh sách đánh giá tại đầu ra ngắn hơn nhiều so với ngưỡng k = 20 (và thường ngắn hơn cả k = 10). Kết quả ở đây vẫn là so sánh mô tả trên một lần chạy, giữa hai chiến lược, và không đủ để kết luận về chất lượng câu trả lời cuối cùng. Chất lượng đó phụ thuộc vào bước sinh câu trả lời và vẫn cần được đánh giá ở RQ5 và RQ6.

Tỷ lệ bao phủ ngân sách ngữ cảnh trong khung đánh giá của ứng dụng là 73,23% đối với section_overlap và 75,59% đối với hierarchical, thấp hơn các giá trị 76,38% và 81,10% đo ở RQ2, vì khung ứng dụng áp dụng đúng cơ chế cắt ngân sách 1.600 token khi nạp ngữ cảnh.

5.4. RQ3 – Đánh giá mô hình embedding và BM25

5.4.1. Thiết lập

Thí nghiệm so sánh BM25 với mười mô hình dense embedding trên 207 bài báo (48 bài Dev và 159 bài held-out), 615 câu hỏi khả giải và 5.207 đoạn văn bản. Các đoạn được tạo bằng `section_overlap` với 350 token và chồng lấp 70 token. Ngưỡng liên quan là $\tau = 0{,}55$. Độ tương đồng cosine được tính chính xác trên vector

FP32, chạy trên CPU AMD Ryzen 5 5600 với bốn luồng. Mô hình đối chiếu là `all-MiniLM-L6-v2`; mô hình đang dùng trong hệ thống là `intfloat/e5-small-v2`. Cấu hình chia đoạn của RQ3 khác với RQ2, nên không được xem là hai thí nghiệm dùng cùng một cấu hình chia đoạn.

5.4.2. Kết quả

Hạng	Mô hình	nDCG@10	nDCG@4	Recall@20	MRR@10
1	modernbert-embed-base	**0,5872**	0,4937	0,9642	0,5438
2	e5-small-v2 (đang dùng)	0,5522	0,4588	0,9623	0,5046
3	snowflake-arctic-embed-m-v1.5	0,5472	0,4531	0,9433	0,5000
4	snowflake-arctic-embed-s	0,5417	0,4453	0,9523	0,4927
5	bge-small-en-v1.5	0,5209	0,4214	0,9542	0,4671
6	nomic-embed-text-v1.5	0,5133	0,4219	0,9553	0,4665
7	mxbai-embed-large-v1	0,5064	0,4177	0,9469	0,4611
8	all-MiniLM-L6-v2 (đối chứng)	0,5026	0,3938	0,9483	0,4417
9	snowflake-arctic-embed-m-v2.0	0,4809	0,3742	0,9481	0,4203
10	BM25	0,4805	0,3779	0,9363	0,4197
11	gte-small	0,4659	0,3585	0,9329	0,4171

Bảng 5.10. Đánh giá chất lượng truy xuất của các mô hình embedding và BM25 (xếp theo nDCG@10)

Mô hình	Tham số (M)	Chiều	Giấy phép	P50 (ms)	Độ trễ P95 (ms)	Đoạn/s	RSS (MB)
modernbert-embed-base	149,0	768	Apache-2.0	103,39	129,75	1,8	1.161,7
e5-small-v2 (đang dùng)	33,4	384	MIT	30,26	40,81	6,5	659,8
snowflake-arctic-embed-m-v1.5	108,9	768	Apache-2.0	74,44	108,48	2,4	956,0
snowflake-arctic-embed-s	33,2	384	Apache-2.0	30,45	40,43	7,0	672,1
bge-small-en-v1.5	33,4	384	MIT	34,14	44,62	6,5	672,3
nomic-embed-text-v1.5	137,0	768	Apache-2.0	110,19	147,64	1,6	1.128,1
mxbai-embed-large-v1	335,1	1024	Apache-2.0	275,34	338,23	0,6	1.292,0
all-MiniLM-L6-v2 (đối chứng)	22,7	384	Apache-2.0	19,30	30,01	19,0	593,1
snowflake-arctic-embed-m-v2.0	305,0	768	Apache-2.0	114,49	141,04	2,2	1.399,5
BM25	0,0	—	Apache-2.0 (rank_bm25)	0,10	0,21	14.673,3	477,9
gte-small	33,4	384	MIT	29,42	37,43	6,3	684,0

Bảng 5.11. Thông số kỹ thuật và chi phí tài nguyên tính toán của các mô hình embedding

Ghi chú: P50 là độ trễ truy vấn trung vị; "Đoạn/s" là thông lượng lập chỉ mục. Với BM25, thông lượng và độ trễ là giá trị do chương trình benchmark ghi nhận và không so sánh trực tiếp được với chi phí mã hóa của mô hình dày.

5.4.3. Thảo luận

ModernBERT-Embed đạt nDCG@10 quan sát cao nhất (0,5872), với độ trễ P50 103,39 ms, thông lượng 1,8 đoạn/giây và RSS đỉnh 1.161,7 MB. Đây là điểm truy xuất cao nhất trong benchmark, đổi lại chi phí CPU và bộ nhớ lớn hơn đáng kể so với E5-Small.

E5-Small-v2 đạt nDCG@10 = 0,5522 với P50 = 30,26 ms, thông lượng 6,5 đoạn/giây và RSS 659,8 MB. Mô hình này đứng thứ hai về chất lượng và cho sự cân bằng thực tế giữa chất lượng truy xuất và chi phí CPU.

Snowflake Arctic Embed S đạt nDCG@10 = 0,5417 và thông lượng 7,0 đoạn/giây. Đây là phương án thay thế đáng cân nhắc, nhưng E5-Small có nDCG@10 quan sát cao hơn ở độ trễ tương đương.

MiniLM là mô hình dày nhanh nhất trong benchmark (19,0 đoạn/giây, P50 = 19,30 ms), với nDCG@10 = 0,5026.

BM25 có độ trễ truy vấn 0,10 ms và thông lượng 14.673,3 đoạn/giây theo benchmark, với nDCG@10 = 0,4805. BM25 phù hợp làm đường cơ sở truy xuất từ khóa và là thành phần tiềm năng cho truy xuất kết hợp ở RQ4. Chênh lệch nhỏ giữa BM25 và một số mô hình dày không được diễn giải là sự kém hơn có ý nghĩa thống kê.

Một số lưu ý cấu hình. Mô hình `snowflake-arctic-embed-m-v2.0` được đánh giá với tiền tố truy vấn dài theo kiểu phiên bản v1.5 ("Represent this sentence for searching relevant passages:") thay vì tiền tố `query:` do tài liệu mô hình v2.0 khuyến nghị. Đây là hạn chế về cấu hình; báo cáo không suy đoán mức độ ảnh hưởng. Ngoài ra, RQ3 có một số bài Dev đã dùng ở các thí nghiệm trước nên không phải là bài kiểm tra mù hoàn toàn, và các số đo độ trễ, bộ nhớ chỉ đúng với môi trường phần cứng này. Giấy phép của `thenlper/gte-small` là MIT.

5.4.4. Quyết định lựa chọn

Hệ thống tiếp tục dùng **`intfloat/e5-small-v2`** vì mô hình này cân bằng giữa chất lượng truy xuất quan sát được và chi phí CPU thực tế. ModernBERT có điểm cao nhất nhưng độ trễ cao hơn, thông lượng thấp hơn và bộ nhớ lớn hơn. Thứ hạng

mô hình ở đây chỉ phản ánh tập dữ liệu và cấu hình đã dùng, không phải thứ hạng có giá trị phổ quát.

5.5. Tổng hợp lựa chọn cấu hình pipeline

Thành phần	Phát hiện liên quan	Quyết định hiện tại
Trích xuất PDF	pymupdf_plain nhanh nhất và có nDCG@10 hạ nguồn cao nhất; pymupdf_layout cung cấp siêu dữ liệu tiêu đề	Dùng pymupdf_layout để hỗ trợ cấu trúc tài liệu
Chia đoạn	hierarchical có điểm truy xuất RQ2 quan sát cao nhất	Điều chỉnh ứng dụng để hỗ trợ truy xuất phân cấp và mở rộng ngữ cảnh cha
Embedding	ModernBERT có nDCG@10 cao nhất; E5-Small cân bằng chất lượng và tài nguyên	Giữ E5-Small làm lựa chọn hiện tại
Truy xuất từ khóa	BM25 rất nhanh và là đường cơ sở truy xuất từ khóa	Xem xét trong RQ4 (truy xuất kết hợp)

Bảng 5.12. Tổng hợp kết quả thành phần và quyết định hiện tại

Các quyết định này dựa trên cả kết quả thực nghiệm lẫn yêu cầu kỹ thuật. Hướng pipeline dự kiến là:

pymupdf_layout → chia đoạn phân cấp (hierarchical chunking) → intfloat/e5-small-v2 → truy xuất đoạn con và mở rộng ngữ cảnh cha → các bước truy xuất/LLM tiếp theo.

Truy xuất phân cấp và mở rộng ngữ cảnh cha đã được triển khai trong ứng dụng và kiểm tra hồi quy ở mục 5.3.5; các khâu truy xuất kết hợp và sinh câu trả lời tối ưu vẫn đang hoàn thiện, và thí nghiệm đầu cuối chưa hoàn thành. Các thành

phần được chọn chưa được chứng minh là tối ưu toàn cục trong sinh câu trả lời đầu cuối.

5.6. Các hướng đánh giá tiếp theo: RQ4–RQ6

RQ4–RQ6 là các giai đoạn đang lên kế hoạch hoặc đang thực hiện, chưa phải thí nghiệm chính thức đã hoàn thành.

- **RQ4 – Truy xuất kết hợp:** Khảo sát việc kết hợp truy xuất dày với truy xuất từ khóa như BM25, có thể dùng Reciprocal Rank Fusion (RRF), trong thiết lập có kiểm soát; đánh giá chất lượng truy xuất, độ trễ và tài nguyên.
- **RQ5 – Sinh câu trả lời:** So sánh các mô hình ngôn ngữ ứng viên về độ chính xác câu trả lời, tính trung thực với bằng chứng được truy xuất, độ chính xác trích dẫn và độ trễ.
- **RQ6 – Pipeline tích hợp:** Kết hợp các cấu hình trích xuất, chia đoạn, embedding, truy xuất và mô hình ngôn ngữ đã chọn; đánh giá chất lượng câu trả lời cuối cùng và chi phí vận hành.

Báo cáo không đưa các số liệu thăm dò của giai đoạn này vào kết quả chính. Các công việc đó chưa được kiểm chứng, nên RQ4–RQ6 được xem là công việc tương lai.

5.7. Giới hạn nghiên cứu

- **Phạm vi lĩnh vực:** QASPER tập trung vào bài báo khoa học máy tính và xử lý ngôn ngữ tự nhiên, nên kết quả không chứng minh khả năng khái quát sang lĩnh vực khác.
- **Tính sẵn có của PDF:** chỉ một phần PDF có sẵn cục bộ (61 tệp), nên kết quả trích xuất giới hạn trong các tài liệu được đánh giá.
- **Tài liệu hóa khảo sát sơ bộ:** thí nghiệm FiQA/QASPER ban đầu thiếu chi tiết thiết lập để so sánh số liệu có kiểm soát với thí nghiệm mở rộng.
- **Khác biệt chỉ số:** nDCG@5 của khảo sát sơ bộ không so sánh trực tiếp được với nDCG@10 của thí nghiệm mở rộng.

- **Cách gán nhãn liên quan:** bao phủ từ vựng của bằng chứng có thể bỏ sót đoạn liên quan về ngữ nghĩa (diễn đạt khác) và có thể thiên về ngữ cảnh cha dài hơn.
- **Trùng lặp corpus:** RQ3 có các bài báo trùng với những đánh giá thành phần trước đó.
- **Phần cứng:** số đo tài nguyên đến từ AMD Ryzen 5 5600 với bốn luồng và có thể khác trên máy khác.
- **Không dùng thống kê suy diễn:** chương chỉ so sánh mô tả, không xác lập ý nghĩa thống kê hay tính vượt trội phổ quát.
- **Chưa có đánh giá chất lượng câu trả lời đầu cuối:** kết quả truy xuất cấp thành phần không đủ để kết luận về tính đúng đắn hay trung thực của câu trả lời.
- **Tích hợp phân cấp:** kiểm tra hồi quy trên pipeline ứng dụng (mục 5.3.5) cho điểm khác benchmark RQ2 và chưa lý giải được hoàn toàn; chất lượng câu trả lời của pipeline tích hợp vẫn cần đánh giá riêng.

Báo cáo cũng không đưa ra số đo thời gian hay bộ nhớ cho các chiến lược chia đoạn vì chưa thu thập các số đo này.

5.8 Kết luận chương

- **RQ1:** `pymupdf_plain` có nDCG@10 hạ nguồn quan sát cao nhất và độ trễ thấp nhất, nhưng `pymupdf_layout` được chọn vì cung cấp thông tin tiêu đề và siêu dữ liệu cấu trúc.
- **RQ2:** khảo sát sơ bộ trên FiQA/QASPER ghi nhận Fixed Size dẫn đầu trong ba chiến lược. Thí nghiệm QASPER mở rộng với tám chiến lược ghi nhận `hierarchical` có các chỉ số truy xuất quan sát cao nhất. Nhóm điều chỉnh kiến trúc ứng dụng để hỗ trợ chia đoạn phân cấp, truy xuất đoạn con và mở rộng ngữ cảnh cha. Kiểm tra hồi quy trên pipeline ứng dụng ghi nhận hierarchical cao hơn section_overlap ở cả bốn chỉ số truy xuất với độ trễ tương đương, nhưng điểm số khác với benchmark RQ2.

- **RQ3:** ModernBERT đạt nDCG@10 quan sát cao nhất, trong khi E5-Small cân bằng chất lượng và tài nguyên tốt hơn và vẫn là lựa chọn hiện tại.
- **RQ4–RQ6:** truy xuất kết hợp, sinh câu trả lời và đánh giá pipeline tích hợp vẫn là công việc đang thực hiện hoặc trong tương lai.

Mọi phát hiện chỉ có giá trị trong phạm vi tập dữ liệu, cách gán nhãn, pipeline và phần cứng đã dùng.

Các thí nghiệm thành phần cung cấp cơ sở có lý lẽ cho thiết kế pipeline, nhưng hệ thống RAG cuối cùng vẫn cần được đánh giá như một thể thống nhất.

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Kết luận

6.1.1 Về phần mềm

Hệ thống phần mềm về cơ bản đã hoàn thiện các chức năng cốt lõi cùng giao diện người dùng trực quan. Tuy nhiên, ứng dụng vẫn tồn tại một số hạn chế kỹ thuật ảnh hưởng đến trải nghiệm người dùng và khả năng vận hành chung.

Về mặt tính năng, giao diện quản lý cộng tác viên phía frontend chưa đồng bộ hoàn toàn với cơ chế phân quyền ở backend. Khả năng xử lý dữ liệu còn phụ thuộc vào phía máy khách do chưa triển khai tìm kiếm toàn văn và phân trang ở phía máy chủ. Quy trình đặt lại mật khẩu qua email tự động vẫn đang trong giai đoạn kết nối tích hợp. Bên cạnh đó, việc lưu trữ tọa độ chú thích PDF theo đơn vị pixel cố định dễ gây sai lệch hiển thị khi thay đổi kích thước màn hình hoặc tỷ lệ thu phóng.

Cuối cùng, hiệu năng của dịch vụ AI chịu ảnh hưởng lớn từ năng lực tính toán của hạ tầng Ollama; dù cơ chế dự phòng có thể cung cấp các trích đoạn liên quan nhưng chưa thể thay thế hoàn toàn khả năng tổng hợp tri thức tự nhiên của mô hình ngôn ngữ lớn.

6.1.2 Về RAG

Kiến trúc RAG đã đạt được những kết quả thực nghiệm ban đầu tích cực và xác định được quy trình chuẩn hóa cho pipeline triển khai. Quá trình xử lý được

định hình từ bước trích xuất cấu trúc văn bản bằng pymupdf_layout, thực hiện chia đoạn phân cấp, biểu diễn ngữ nghĩa qua mô hình nhúng và tiến hành truy xuất ở cấp độ đoạn con trước khi mở rộng sang ngữ cảnh của đoạn cha tương ứng.

Về chiến lược lưu trữ và truy xuất, phương pháp chia đoạn phân cấp thể hiện tiềm năng lớn trong việc duy trì ngữ cảnh toàn diện. Trong khi đó, việc lựa chọn mô hình nhúng intfloat/e5-small-v2 đã chính thức hoàn tất nhờ đạt được sự cân bằng tối ưu giữa chi phí tính toán và chất lượng truy xuất thông tin.

6.2 Hướng phát triển

6.2.1 Về phần mềm

Nghiên cứu sẽ tập trung khắc phục các điểm hạn chế kỹ thuật hiện tại nhằm tối ưu hóa hạ tầng và nâng cao trải nghiệm người dùng. Giao diện ứng dụng sẽ nâng cấp cơ chế trích dẫn để tô sáng chính xác các vùng văn bản tham chiếu trên tài liệu PDF khi mô hình phản hồi.

Tính năng chia sẻ và cộng tác sẽ được phát triển hoàn thiện ở frontend, cho phép quản lý không gian làm việc trực quan. Hệ thống sẽ chuyển đổi toàn bộ cơ chế tìm kiếm, lọc dữ liệu và phân trang sang xử lý phía máy chủ kết hợp chỉ mục tìm kiếm toàn văn, đồng thời hoàn thiện API kết nối dịch vụ gửi email xác thực an toàn cho quy trình đặt lại mật khẩu.

Ngoài ra, việc lưu trữ chú thích PDF sẽ chuyển sang biểu diễn theo tỷ lệ phần trăm tương đối để đảm bảo hiển thị nhất quán trên mọi thiết bị. Cuối cùng, giải pháp cân bằng tải cho hạ tầng Ollama và các chiến lược dự phòng linh hoạt sẽ được triển khai nhằm duy trì sự ổn định của hệ thống trong điều kiện tài nguyên hạn chế.

6.2.2 Về RAG

Định hướng phát triển RAG sẽ tập trung nâng cấp toàn diện các công đoạn truy xuất và tổng hợp thông tin. Hệ thống sẽ tích hợp mô hình tìm kiếm kết hợp giữa từ khóa BM25 và ngữ nghĩa Dense Retrieval nhằm xử lý hiệu quả các thuật ngữ chuyên ngành cùng tên riêng.

Ngay sau bước truy xuất ban đầu, nghiên cứu sẽ tiến hành khảo sát, thử nghiệm và lựa chọn các mô hình tinh chỉnh thứ tự (Cross-Encoder Reranker) phù hợp, đồng thời thiết lập chiến lược lọc danh sách rút gọn (Shortlisting) tối ưu nhằm đánh giá chính xác độ tương đồng thực sự và loại bỏ nhiễu trước khi chuyển ngữ cảnh cho mô hình ngôn ngữ lớn. Bên cạnh đó, phương pháp chia đoạn phân cấp và cơ chế Small-to-Big sẽ tiếp tục được thử nghiệm mở rộng trên nhiều bộ dữ liệu thuộc các lĩnh vực khác nhau để xác định kích thước đoạn tối ưu.

Cuối cùng, hệ thống sẽ tiến hành đánh giá so sánh trực tiếp các mô hình nhúng ngữ nghĩa thế hệ mới với intfloat/e5-small-v2 nhằm hướng tới một pipeline RAG đạt độ chính xác cao, thời gian phản hồi thấp và khả năng mở rộng linh hoạt.

TÀI LIỆU THAM KHẢO

Tiếng Anh

[1] Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems (NeurIPS 2020)*. https://arxiv.org/abs/2005.11401

[2] Dasigi, P., et al. (2021). A Dataset of Information-Seeking Questions and Answers Anchored in Research Papers. *Proceedings of NAACL-HLT 2021*, 4599–4610. https://doi.org/10.18653/v1/2021.naacl-main.365

[3] Brown, A., Roman, M., & Devereux, B. (2025). A Systematic Literature Review of Retrieval-Augmented Generation: Techniques, Metrics, and Challenges. https://arxiv.org/abs/2508.06401

[4] Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends® in Information Retrieval*, 3(4), 333–389. https://doi.org/10.1561/1500000019

[5] Thakur, N., Reimers, N., Rücklé, A., Srivastava, A., & Gurevych, I. (2021). BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks 1 (NeurIPS Datasets and Benchmarks 2021)*. https://arxiv.org/abs/2104.08663